

UNIVERSIDAD NACIONAL DEL ALTIPLANO - PUNO

FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA,
ELECTRÓNICA Y SISTEMAS

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS



DETECCIÓN DE ATAQUES MINORITARIOS EN REDES IoT
MEDIANTE UN MODELO HÍBRIDO BASADO EN
STACKING, XGBOOST Y LIGHTGBM, PUNO 2026

BORRADER DE TESIS

PRESENTADA POR:

CARMEN NIEVES APAZA CONDORI

PARA OPTAR EL TÍTULO PROFESIONAL DE:

INGENIERO DE SISTEMAS

PUNO - PERÚ

2026

UNIVERSIDAD NACIONAL DEL ALTIPLANO

PUNO

FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA, ELECTRÓNICA Y
SISTEMAS

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS
TESIS

DETECCIÓN DE ATAQUES MINORITARIOS EN REDES IOT MEDIANTE UN
MODELO HÍBRIDO BASADO EN STACKING, XGBOOST Y LIGHTGBM

PUNO 2026

Presentado por:

Bach. Carmen Nieves Apaza Condori

Para optar el título profesional de:

INGENIERO DE SISTEMAS

APROBADA POR:

PRESIDENTE: Pablo Cesar Tapia Catacora
Dr. Presidente de Jurado

PRIMER MIEMBRO: Carlos Boris Sosa Maydana
Dr. Primer miembro de Jurado

SEGUNDO MIEMBRO: Ubaldo Allca Mamani
Dr. Segundo miembro de Jurado

DIRECTOR / ASESOR: Hugo Yosef Gomez Quispe
Dr. Asesor de Tesis

Área: Inteligencia Artificial

Tema: Detección de ataques minoritarios en redes IoT mediante modelo híbrido
basado en Stacking, XGBoost y LightGBM

ÍNDICE GENERAL

Índice General	6
Índice de Tablas	7
Índice de Figuras	8
Índice de Acrónimos	9
Resumen	10
Abstract	11
1. INTRODUCCIÓN	1
1.1.. CONTEXTUALIZACIÓN	1
1.2.. REALIDAD PROBLEMÁTICA	2
1.3.. FORMULACIÓN DEL PROBLEMA	3
1.3.1.. Problema General	3
1.3.2.. Problemas Específicos	3
1.4.. JUSTIFICACIÓN	4
1.4.1.. Justificación Técnica y Científica	4
1.4.2.. Justificación Económica y Operativa	4
1.4.3.. Justificación Social y Práctica	5
1.5.. OBJETIVOS	5
1.5.1.. OBJETIVO GENERAL	5
1.5.2.. OBJETIVOS ESPECÍFICOS	5
1.6.. HIPÓTESIS DE LA INVESTIGACIÓN	6
1.6.1.. Hipótesis general	6
1.6.2.. Hipótesis específicas	6
1.7.. VARIABLES	6
1.7.1.. Variable Independiente (VI)	6

1.7.2..	Variable Dependiente (VD)	7
1.8..	OPERACIONALIZACIÓN DE VARIABLES	8
2.	REVISIÓN DE LITERATURA	9
2.1..	Antecedentes de la Investigación	9
2.1.1..	Antecedentes internacionales	9
2.1.2..	Antecedentes nacionales	16
2.2..	Marco Teórico	19
2.2.1..	Internet de las Cosas (IoT)	19
2.2.1.1..	Arquitectura distribuida y capas de red	19
2.2.1.2..	Dispositivos de borde y pasarelas IoT (IoT Gateways)	20
2.2.1.3..	Restricciones computacionales, de memoria y latencia	21
2.2.1.4..	Protocolos de comunicación de transporte (TCP/IP vs. UDP)	21
2.2.2..	Ciberseguridad y Detección de Intrusiones	22
2.2.2.1..	Sistemas de Detección de Intrusiones (IDS)	22
2.2.2.2..	Arquitecturas NIDS vs. HIDS	22
2.2.2.3..	Caracterización del tráfico con el dataset CICIoT2023	22
2.2.2.4..	Taxonomía de ciberataques: Volumétricos vs. Minoritarios	23
2.2.3..	Desbalance de Datos y Preprocesamiento	24
2.2.3.1..	Teorema del No Free Lunch y Desbalance de Clases	24
2.2.3.2..	Índice de Desbalance (Imbalance Ratio - IR)	24
2.2.3.3..	Sesgo algorítmico y Paradoja de la Exactitud (Accuracy Paradox)	25
2.2.3.4..	Escalado Robusto Adaptativo (RobustScaler)	25
2.2.3.5..	Sobremuestreo Sintético en la Frontera (Borderline-SMOTE1)	26
2.2.4..	Algoritmos de Aprendizaje Automático Base (Nivel 0)	27
2.2.4.1..	Teoría de Ensamble y Compromiso Sesgo-Varianza	27
2.2.4.2..	Random Forest (Bagging e Impureza de Gini)	28
2.2.4.3..	XGBoost GPU (Gradient Boosting regularizado de 2º orden)	28

2.2.4.4..	LightGBM (Crecimiento por hojas Leaf-wise, GOSS y EFB)	29
2.2.5..	Cuantificación de Incertidumbre Predictiva	30
2.2.5.1..	Teoría de la Información de Shannon	30
2.2.5.2..	Entropía de Shannon como métrica de ambigüedad pre- dictiva	30
2.2.6..	Arquitectura de Ensamble por Stacking Híbrido	32
2.2.6.1..	Principios teóricos del Stacking (Stacked Generalization) .	32
2.2.6.2..	Generación de Meta-características fuera de pliegue (OOF)	32
2.2.6.3..	Meta-Modelo de Nivel 1 (LightGBM)	33
2.2.7..	Métricas de Evaluación y Prueba Estadística	33
2.2.7.1..	Métricas de clasificación multiclase	33
2.2.7.2..	Perfilado de rendimiento computacional	34
2.2.7.3..	Prueba Estadística No Paramétrica de Wilcoxon	35
2.3..	Definición de Términos Básicos	36
3.	MATERIALES Y MÉTODOS	40
3.1..	Diseño Metodológico	40
3.1.1..	Tipo de Investigación	40
3.1.2..	Diseño de Investigación y Control de Variables	40
3.1.3..	Marco de Trabajo Metodológico: CRISP-DM Adaptado	41
3.2..	Unidades de Análisis, Población y Muestra	43
3.2.1..	Población Objetivo y Procedencia del Dataset	43
3.2.2..	Técnica de Muestreo Estratificado y Partición Experimental	43
3.3..	Procedimiento de Tratamiento y Preprocesamiento del Dataset	45
3.3.1..	Depuración de Datos: Tratamiento de Duplicados, Valores Nulos e Infinitos	46
3.3.2..	Selección de Atributos y Normalización con RobustScaler	46
3.3.3..	Rebalanceo de Clases Minoritarias mediante Borderline-SMOTE1 .	47
3.4..	Entorno de Instrumentación y Desarrollo	48
3.4.1..	Especificaciones de Hardware	48

3.4.2..	Entorno de Software, Librerías y Artefactos de Código	49
3.5..	Plan de Validación, Replicabilidad y Control de Amenazas	50
3.5.1..	Procedimiento de Experimentación y Entrenamiento del Modelo . .	50
3.5.2..	Control de Amenazas a la Validez Interna y Externa	51
3.5.3..	Validación de Significancia Estadística (Prueba de Wilcoxon) . . .	52
4.	RESULTADOS Y DISCUSIÓN	53
4.1..	Recopilación y Análisis del Conjunto de Datos (Fase CRISP-DM 1 y 2) . .	53
4.2..	Tratamiento, Selección y Rebalanceo de Datos (Fase CRISP-DM 3)	54
4.2.1..	Filtrado de Duplicados e Higiene de Datos	54
4.2.2..	Selección de Atributos mediante Impureza de Gini	55
4.2.3..	Sobremuestreo Adaptativo en la Frontera con Borderline-SMOTE1	56
4.3..	Diseño, Entrenamiento y Evaluación del Modelo Híbrido (Fase CRISP-DM	
	4, 5 y 6)	57
4.3.1..	Evaluación Métrica de Clasificación Multiclase	57
4.3.2..	Perfilado de Rendimiento Computacional	58
4.3.3..	Prueba Estadística de Hipótesis (Prueba de Wilcoxon)	59
4.4..	Discusión	60
4.4.1..	Evaluación del Rendimiento General en Relación al Objetivo Gene- ral y la Hipótesis General	60
4.4.2..	Mitigación del Sesgo Algorítmico y Detección de Ataques Minori- tarios en Relación al Objetivo Específico 1 y la Hipótesis Específica 1	61
4.4.3..	Aportación de la Entropía de Shannon y la Arquitectura Stacking en Relación al Objetivo Específico 2 y la Hipótesis Específica 2 . .	62
4.4.4..	Perfilado Computacional de Viabilidad y Validación Estadística en Relación al Objetivo Específico 3 y la Hipótesis Específica 3	63
5.	CONCLUSIONES	64
6.	RECOMENDACIONES	66

REFERENCIAS BIBLIOGRÁFICAS	68
Anexos	72

ÍNDICE DE TABLAS

1.1. Matriz de Operacionalización de Variables de la Investigación	8
3.1. Fases metodológicas de CRISP-DM y su mapeo con los notebooks del proyecto	42
3.2. Distribución de clases en la muestra consolidada y la partición experimental (Train/Test)	44
3.3. Vector de 29 características de red seleccionadas para el modelado	47
3.4. Especificaciones del entorno de hardware empleado en la investigación . . .	48
3.5. Plataforma de software, entorno virtual y librerías utilizadas	49
4.1. Desempeño predictivo comparativo sobre el conjunto de prueba aislado (377,383 muestras)	57
4.2. Perfilado computacional de latencia de inferencia y uso de memoria RAM .	58
4.3. Resultados de la Prueba de Rangos con Signo de Wilcoxon ($\alpha = 0,05$) . . .	59
6.1. Hiperparámetros óptimos seleccionados para los clasificadores del ensamble	73
6.2. Prueba de Rangos con Signo de Wilcoxon sobre 30 bloques independientes	74

ÍNDICE DE FIGURAS

2.1.	Arquitectura distribuida de cuatro capas funcionales en entornos IoT . . .	20
2.2.	Topología de frontera y generación sintética de instancias con Borderline-SMOTE1	26
2.3.	Comportamiento de la Entropía de Shannon según la dispersión del vector de probabilidad	31
3.1.	Flujo metodológico CRISP-DM adaptado a la investigación	43
3.2.	Diagrama de flujo del pipeline de preprocesamiento de datos	45
3.3.	Arquitectura del Modelo Híbrido Stacking con Entropía de Shannon	51
4.1.	Distribución empírica de frecuencias por categoría de tráfico en la muestra consolidada	53
4.2.	Comparación del volumen de datos antes y después del proceso de limpieza y eliminación de duplicados	55
4.3.	Importancia relativa de las 29 características de red seleccionadas	56
4.4.	Distribución de frecuencias por clase en el conjunto de entrenamiento antes y después de aplicar Borderline-SMOTE1	56
4.5.	Matriz de confusión multiclase del Stacking Híbrido propuesto sobre el conjunto de prueba aislado	58
4.6.	Distribución del F1-Macro en 30 bloques de evaluación: Stacking Híbrido vs. Modelos Base	59

ÍNDICE DE ACRÓNIMOS

API	Application Programming Interface (Interfaz de Programación de Aplicaciones)
CIC-IoT	Canadian Institute for Cybersecurity Internet of Things (Instituto Canadiense de Ciberseguridad para IoT)
DoS	Denial of Service (Denegación de Servicio)
IDPS	Intrusion Detection and Prevention System (Sistema de Detección y Prevención de Intrusiones)
IoT	Internet of Things (Internet de las Cosas)
ML	Machine Learning (Aprendizaje Automático)
NIDS	Network Intrusion Detection System (Sistema de Detección de Intrusiones de Red)
RF	Random Forest (Bosque Aleatorio)
SVM	Support Vector Machine (Máquina de Vectores de Soporte)
XGBoost	eXtreme Gradient Boosting (Gradient Boosting Extremo)
LightGBM	Light Gradient Boosting Machine (Máquina de Gradient Boosting Ligero)
Stacking	Stacking Ensemble (Aprendizaje por Apilamiento)
IoTMT	IoT Malware Traffic (Tráfico de Malware IoT)
IDS	Intrusion Detection System (Sistema de Detección de Intrusiones)
MLP	Multi-Layer Perceptron (Perceptrón Multicapa)
CNN	Convolutional Neural Network (Red Neuronal Convolutacional)
LSTM	Long Short-Term Memory (Memoria de Corto y Largo Plazo)

RESUMEN

El despliegue de infraestructuras del Internet de las Cosas (IoT) en organizaciones y micro, pequeñas y medianas empresas (MYPEs y PYMEs) enfrenta severas vulnerabilidades ante la baja sensibilidad de los Sistemas de Detección de Intrusiones (IDS) convencionales frente a ciberataques minoritarios infrecuentes (Web-based y Brute Force). La presente investigación tuvo como objetivo desarrollar y evaluar en entorno de laboratorio un modelo de clasificación híbrido basado en la arquitectura Stacking de dos niveles, integrando Random Forest, XGBoost GPU y LightGBM con cuantificación de incertidumbre por Entropía de Shannon y sobremuestreo adaptativo en la frontera a través de Borderline-SMOTE1 sobre el dataset CICIoT2023. La metodología siguió un enfoque cuantitativo, de tipo aplicado y diseño cuasi-experimental. La muestra consolidada comprendió 2,515,889 flujos de red depurados de nulos, infinitos y duplicados, particionados en 80% para entrenamiento y 20% para evaluación en prueba aislada (377,383 muestras). Los resultados demostraron que el Stacking Híbrido propuesto alcanzó un F1-Macro del 70.18% y una exactitud (Accuracy) del 84.85%, superando a los modelos individuales (XGBoost 69.60%, LightGBM 69.53%, Random Forest 67.91%, CART 66.51% y Regresión Logística 42.20%). En el perfilado computacional registró una latencia de inferencia de apenas 8,65 μs por flujo y 257,89 MB de memoria RAM, garantizando viabilidad operativa para pasarelas de borde. La Prueba de Rangos con Signo de Wilcoxon ($p = 0,003744 < 0,05$) confirmó la superioridad estadística de la propuesta. Se concluye que la hibridación de clasificadores heterogéneos con metadatos entrópicos y rebalanceo de frontera constituye una solución altamente eficaz y liviana para proteger redes IoT.

Palabras clave: Internet de las Cosas, Ciberseguridad, Stacking Híbrido, Ataques Minoritarios, Entropía de Shannon, Borderline-SMOTE, CICIoT2023.

ABSTRACT

The deployment of Internet of Things (IoT) infrastructures in organizations and micro, small, and medium-sized enterprises (MSMEs) faces severe vulnerabilities due to the low sensitivity of conventional Intrusion Detection Systems (IDS) against infrequent minority cyberattacks (Web-based and Brute Force). This research aimed to develop and evaluate in a laboratory environment a hybrid classification model based on a two-level Stacking architecture, integrating Random Forest, XGBoost GPU, and LightGBM with entropic uncertainty quantification via Shannon Entropy and adaptive boundary oversampling through Borderline-SMOTE1 on the benchmark dataset CICIoT2023. The methodology followed a quantitative approach, applied type, and quasi-experimental design. The consolidated sample comprised 2,515,889 network flows cleaned of nulls, infinities, and duplicates, partitioned into 80% for training and 20% for isolated testing (377,383 samples). The results demonstrated that the proposed Hybrid Stacking model achieved an F1-Macro of 70.18% and an Accuracy of 84.85%, outperforming all baseline models (XGBoost 69.60%, LightGBM 69.53%, Random Forest 67.91%, CART 66.51%, and Logistic Regression 42.20%). Computational profiling revealed an inference latency of just $8,65\mu s$ per flow and 257,89 MB of RAM, ensuring operational feasibility for edge gateways. The Wilcoxon Signed-Rank Test ($p = 0,003744 < 0,05$) confirmed the statistical superiority of the proposed framework. It is concluded that combining heterogeneous classifiers with entropic metadata and boundary resampling provides a highly effective and lightweight security solution for IoT networks.

Keywords: Internet of Things, Cybersecurity, Hybrid Stacking, Minority Attacks, Shannon Entropy, Borderline-SMOTE, CICIoT2023.

CAPÍTULO I

INTRODUCCIÓN

1.1. CONTEXTUALIZACIÓN

El despliegue masivo de dispositivos interconectados bajo el paradigma del Internet de las Cosas (IoT) ha transformado radicalmente la infraestructura digital global, facilitando la automatización en sectores críticos como la industria 4.0, la gestión de ciudades inteligentes, la telemedicina y el monitoreo ambiental. Sin embargo, esta rápida expansión ha incrementado exponencialmente la superficie de exposición ante ciberamenazas cada vez más complejas y destructivas. La naturaleza heterogénea de las arquitecturas de red IoT, sumada a las severas restricciones intrínsecas de hardware (limitaciones de procesamiento, memoria y energía en los nodos finales), dificulta significativamente la implementación de mecanismos de seguridad tradicionales como cortafuegos pesados o sistemas de inspección profunda de paquetes (Sama et al., 2025).

A pesar del continuo avance en el desarrollo de Sistemas de Detección de Intrusiones (IDS) basados en aprendizaje automático (Machine Learning), la identificación de anomalías en entornos de red reales enfrenta un desafío técnico crítico: el desbalance extremo de clases. En escenarios operativos reales, el volumen de tráfico benigno y de ataques masivos de denegación de servicio (DDoS) abruma cuantitativamente a los registros de red, mientras que los vectores de ataque más sofisticados y sigilosos (como las inyecciones Web, desbordamientos de búfer o ataques de fuerza bruta) ocurren con una frecuencia significativamente baja (Ahmed et al., 2024). Esta subrepresentación provoca que los clasificadores convencionales sufran un sesgo algorítmico, optimizando la exactitud global a costa de ignorar las muestras de las clases minoritarias, las cuales representan las brechas de seguridad más disruptivas.

Para mitigar esta vulnerabilidad, la comunidad científica ha comenzado a explorar arquitecturas de aprendizaje jerárquico o Stacking. No obstante, la simple combinación de clasificadores resulta insuficiente si no se incorporan mecanismos formales para cuantificar

la incertidumbre predictiva en las fronteras de decisión desbalanceadas. En este sentido, la integración de métricas entrópicas (como la Entropía de Shannon) para evaluar el grado de confusión de los clasificadores base, junto con técnicas avanzadas de sobremuestreo en la frontera como Borderline-SMOTE, permite reequilibrar la importancia de las clases minoritarias sin generar ruido sintético perjudicial (Popoola et al., 2025; Nigar & Mustafa, 2025). La formulación de un modelo híbrido basado en la sinergia de Random Forest, XGBoost y LightGBM bajo un meta-clasificador superior ofrece una solución con alta capacidad de generalización y latencia de inferencia ultra-baja para redes IoT.

1.2. REALIDAD PROBLEMÁTICA

A nivel internacional, la adopción masiva de tecnologías basadas en el Internet de las Cosas (IoT) en sectores industriales y comerciales ha expuesto a las organizaciones a crecientes amenazas cibernéticas. Las pequeñas y medianas empresas (PYMEs) a escala global enfrentan serios desafíos para proteger sus entornos digitales debido a la falta de sistemas de ciberseguridad adaptados a sus capacidades tecnológicas (Ciampi et al., 2021). Si bien el aprendizaje automático (Machine Learning) ofrece alternativas prometedoras para la detección de intromisiones, la mayoría de las soluciones existentes sufren de un severo rendimiento deficiente al lidiar con conjuntos de datos altamente desbalanceados, como el benchmark internacional CICIoT2023, donde los ataques más destructivos y sigilosos (como ataques basados en Web y fuerza bruta) representan menos del 1% del tráfico total, siendo pasados por alto por los clasificadores convencionales (Nigar & Mustafa, 2025).

A nivel nacional, en el Perú, las micro y pequeñas empresas (MYPEs) y medianas empresas (PYMEs) constituyen más del 98% del tejido productivo, desempeñando un rol clave en la economía y la generación de empleo. No obstante, la rápida digitalización e incorporación de dispositivos IoT en estos entornos se produce en un contexto de alta vulnerabilidad cibersegura, caracterizado por presupuestos limitados y ausencia de herramientas de detección de amenazas adaptadas a la realidad tecnológica del país (López-García et al., 2023). La literatura nacional en este ámbito, como los estudios realizados sobre el dataset CICIoT2023 por Raico Gallardo (2025), demuestra que los clasificadores individuales logran detectar el tráfico masivo pero fallan drásticamente en la identificación

de intrusiones de baja frecuencia, evidenciando la falta de modelos integrados que aborden el rebalanceo de clases y el análisis de incertidumbre en el contexto de la ciberseguridad nacional (Vargas-Hernández et al., 2022).

A nivel regional, en la región de Puno y el sur del Perú, la pequeña y mediana empresa dedicada a la producción, comercio y servicios experimenta una paulatina automatización mediante sensores y dispositivos conectados. Sin embargo, este proceso se desarrolla bajo limitaciones de infraestructura de red y recursos computacionales reducidos (Quispe-Mamani et al., 2023). En este escenario, la implementación de modelos de detección de intrusos probados a nivel de laboratorio representa una necesidad urgente para evaluar la factibilidad técnica y computacional de soluciones eficientes. Por tanto, la presente investigación aborda la falta de un modelo híbrido optimizado mediante la integración de Borderline-SMOTE, Entropía de Shannon y Stacking de clasificadores en entorno de laboratorio, permitiendo elevar la tasa de detección de ataques minoritarios con un mínimo consumo de recursos.

1.3. FORMULACIÓN DEL PROBLEMA

1.3.1. Problema General

¿En qué medida el Modelo híbrido basado en Stacking, XGBoost y LightGBM mejora la eficacia en la detección de ataques minoritarios en redes IoT?

1.3.2. Problemas Específicos

- PE1: ¿En qué grado la técnica de rebalanceo Borderline-SMOTE incrementa la proporción de balance de la clase minoritaria en el dataset CICIoT2023 respecto al balance original?
- PE2: ¿Cuál es la capacidad de detección del Modelo híbrido basado en Stacking, XGBoost y LightGBM en la identificación de ataques minoritarios evaluada mediante las métricas de evaluación Recall, F1-Score y Accuracy?

- PE3: ¿Cuál es la eficiencia computacional del Modelo híbrido basado en Stacking, XGBoost y LightGBM propuesto en términos de tiempos de entrenamiento y latencia de inferencia frente a los modelos base Random Forest y XGBoost?

1.4. JUSTIFICACIÓN

1.4.1. Justificación Técnica y Científica

La investigación se justifica técnicamente por la necesidad de superar las limitaciones de los clasificadores individuales ante datos desbalanceados en redes IoT. La literatura científica reciente (Sama et al., 2025; Ahmed et al., 2024) demuestra que los enfoques de ensamble por Stacking superan a los modelos independientes en capacidad de generalización. Sin embargo, esta propuesta evoluciona el estado del arte al integrar la Entropía de Shannon como una variable cuantitativa de incertidumbre dentro del vector de meta-características (27 atributos formados por 24 probabilidades de clase y 3 indicadores entrópicos), permitiendo al meta-modelo LightGBM discernir con precisión en las regiones de mayor confusión. Asimismo, la aplicación de Borderline-SMOTE exclusivamente en el conjunto de entrenamiento fortalece las fronteras de decisión de las clases minoritarias (Web-based y Brute Force) sin incurrir en la fuga de datos (data leakage), ofreciendo un protocolo metodológico libre de sesgos.

1.4.2. Justificación Económica y Operativa

Desde una perspectiva operativa y de laboratorio, los entornos de prueba para redes IoT requieren validar soluciones con alta velocidad de respuesta y bajo consumo de memoria. Los modelos basados en aprendizaje profundo (Deep Learning) exigen recursos de hardware elevados y tiempos de ejecución prolongados. El modelo propuesto en esta investigación demuestra una alta eficiencia en condiciones de laboratorio, alcanzando una latencia de inferencia de apenas **$8,65\mu s$** por muestra (equivalente a más de 115,000 paquetes evaluados por segundo) y un consumo de memoria RAM de **257,89 MB**, lo que fundamenta su viabilidad técnica para futuras implementaciones en dispositivos con recursos limitados.

1.4.3. Justificación Social y Práctica

La relevancia social radica en proporcionar evidencia empírica y tecnológica que permita proteger la integridad y privacidad de las redes de información en MYPEs y PYMEs de la región y del país. Los ataques no detectados en sistemas de pequeñas empresas pueden ocasionar pérdidas económicas severas o la interrupción de sus actividades comerciales. La validación experimental de este modelo sobre los 63 archivos oficiales del dataset CICIoT2023 proporciona a la comunidad académica y técnica una herramienta de ciberseguridad proactiva, reproducible y de bajo costo computacional.

1.5. OBJETIVOS

1.5.1. OBJETIVO GENERAL

Determinar la eficacia del Modelo Híbrido basado en Stacking, XGBoost y LightGBM en la mejora de la detección de ataques minoritarios en redes IoT.

1.5.2. OBJETIVOS ESPECÍFICOS

- OE1: Evaluar la mejora en la proporción de balance de la clase minoritaria mediante la aplicación de la técnica de rebalanceo Borderline-SMOTE en el dataset CICIoT2023.
- OE2: Determinar la capacidad de detección del Modelo Híbrido basado en Stacking, XGBoost y LightGBM en la identificación de ataques minoritarios utilizando las métricas de evaluación Recall, F1-Score y Accuracy.
- OE3: Comparar la eficiencia computacional del modelo híbrido propuesto midiendo los tiempos de entrenamiento y latencia de inferencia frente a los modelos base Random Forest y XGBoost.

1.6. HIPÓTESIS DE LA INVESTIGACIÓN

1.6.1. Hipótesis general

El Modelo Híbrido basado en Stacking, XGBoost y LightGBM mejora significativamente la eficacia (Recall y F1-Score) en la detección de ataques minoritarios en redes IoT, superando el rendimiento de los modelos base en el dataset CICIoT2023.

1.6.2. Hipótesis específicas

- HE1: La técnica de rebalanceo Borderline-SMOTE incrementa significativamente la proporción de balance de la clase minoritaria en el dataset CICIoT2023, reduciendo el índice de desbalance y mejorando la distribución de datos en la frontera de decisión.
- HE2: El Modelo Híbrido XGB-LGBM-Stacking con análisis de incertidumbre presenta una alta capacidad de detección de ataques minoritarios, evidenciando indicadores superiores en las métricas de Recall, F1-Score y Accuracy al ser validados estadísticamente mediante la prueba de rangos con signo de Wilcoxon.
- HE3: El modelo híbrido propuesto optimiza la eficiencia computacional, logrando tiempos de entrenamiento y una latencia de inferencia competitivos en comparación con los modelos base Random Forest y XGBoost, garantizando su viabilidad operativa.

1.7. VARIABLES

1.7.1. Variable Independiente (VI)

Modelo híbrido basado en Stacking, XGBoost y LightGBM, optimizado con la técnica de rebalanceo de datos Borderline-SMOTE.

1.7.2. Variable Dependiente (VD)

Detección de ataques minoritarios en redes IoT, evaluada a través de la eficacia predictiva y el desempeño computacional.

1.8. OPERACIONALIZACIÓN DE VARIABLES

Tabla 1.1

Matriz de Operacionalización de Variables de la Investigación

Variable	Definición Conceptual	Definición Operacional	Dimensiones	Indicadores	Escala
Variable In- dependiente: Modelo Híbrido Stacking (RF, XGBoost, LightGBM) con Entropía de Shannon y Borderline- SMOTE	Arquitectura jerárquica de dos niveles que combina predicciones de clasificadores base (Nivel 0) con cuantificación de incertidumbre entrópica y sobremuestreo sintético en la frontera de decisión.	Pipeline computacional en Python (Conda tesis_iot) que aplica Borderline- SMOTE en entrenamiento, selecciona 29 atributos, extrae 27 meta- características (24 probs + 3 entropías) y entrena un meta- LightGBM.	1. Preproce- samiento y Rebalanceo. 2. Arquitectura de Ensamble (Nivel 0 y 1).	1. Ratio de balanceo sintético. 2. Algoritmos base (RF, XGBoost GPU, LightGBM). 3. Entropía de Shannon (H). 4. Parámetros del Meta- LightGBM.	Nominal / Razón
Variable Dependiente: Detección de ataques minoritarios en redes IoT	Capacidad para identificar e inferir correctamente flujos de red anómalos de baja frecuencia (Web-based, Brute Force) evaluando la	Evaluación experimental sobre 377,383 muestras de prueba aisladas del dataset CICIoT2023, registrando 8 métricas de clasificación y	1. Eficacia Predictiva. 2. Desempeño Computacio- nal. 3. Significancia Estadística.	1. Accuracy Global (%). 2. Sensitivity / Recall. 3. F1-Macro / F1-Score por clase. 4. Latencia de inferencia (μ s/muestra).	Razón / Intervalo

CAPÍTULO II

REVISIÓN DE LITERATURA

2.1. ANTECEDENTES DE LA INVESTIGACIÓN

2.1.1. Antecedentes internacionales

Abou Elasaad et al. (2025), en su artículo *AegisGuard: A Multi-Stage Hybrid Intrusion Detection System with Optimized Feature Selection for Industrial IoT Security*, propusieron un estudio experimental orientado a fortalecer ecosistemas IIoT mediante arquitecturas de análisis secuencial. La metodología implementó AegisGuard, un modelo modular de múltiples etapas que filtra flujos maliciosos aplicando selección dinámica de características. Los resultados evidenciaron empíricamente que este enfoque estratificado supera estadísticamente a los sistemas de etapa única en la neutralización asertiva de ciberataques estructuralmente complejos. Este trabajo respalda concluyentemente el paradigma de construir arquitecturas híbridas y multicapa; sin embargo, no atiende primariamente el sesgo algorítmico generado por clases minoritarias subrepresentadas en la capa de entrada, variable crítica que esta tesis subsanará empleando el algoritmo Borderline-SMOTE.

Adewole et al. (2025), en *Intrusion Detection Framework for Internet of Things with Rule Induction for Model Explanation*, ejecutaron un diseño experimental para integrar capacidades de explicabilidad en sistemas de ciberseguridad IoT. Metodológicamente, utilizaron los conjuntos de datos CIC-IDS2017 y CICIoT2023 para evaluar el rendimiento de algoritmos de Gradient Boosting, incluyendo XGBoost, LightGBM y CatBoost. Los resultados demostraron la superioridad técnica de XGBoost, el cual alcanzó un Accuracy de 99.91% en el primer dataset, 98.54% en el CICIoT2023 y un AUC-ROC global de 93.06%. Este trabajo justifica rigurosamente la elección de XGBoost como algoritmo base competente; no obstante, no implementa técnicas de rebalanceo avanzado, requerimiento metodológico indispensable que la presente investigación abordará.

Ahmed et al. (2024), en *An optimized ensemble model with advanced feature selection for network intrusion detection*, realizaron un estudio de nivel explicativo con el

objetivo de optimizar la identificación de amenazas mediante la hibridación de algoritmos predictivos. La metodología consistió en integrar los modelos XGBoost y LightGBM bajo una arquitectura de ensamble tipo Stacking, evaluando el impacto de la remoción de atributos irrelevantes en la estabilidad sistémica. Los resultados confirmaron que la mitigación del ruido de entrada acelera significativamente el entrenamiento e incrementa la precisión global del clasificador. La relevancia de esta investigación radica en validar la efectividad estructural del modelo Stacking seleccionado; sin embargo, carece de un enfoque orientado específicamente a métricas de ataques minoritarios, dimensión que será el núcleo de evaluación del modelo propuesto en esta tesis.

Al-Emari et al. (2024), en su artículo *Employing Mutual Information Feature Selection and LightGBM for Intrusion Detection in IoT*, desarrollaron una investigación aplicada cuyo objetivo fue optimizar los mecanismos de protección de redes mediante la selección heurística de características. Metodológicamente, emplearon el algoritmo LightGBM evaluado sobre el conjunto de datos IoTID20, integrando el análisis de Información Mutua y optimización por enjambre de partículas. Los resultados revelaron que esta configuración supera a las técnicas convencionales en las métricas de exactitud, sensibilidad y F1-Score, reduciendo simultáneamente la tasa de falsos positivos. Este estudio demuestra fehacientemente la eficacia del clasificador LightGBM para entornos IoT; sin embargo, al utilizar un dataset genérico y optimizaciones de alto costo, deja un vacío técnico que la presente tesis cubrirá mediante el dataset CICIoT2023.

Almotairi et al. (2024), en *Enhancing intrusion detection in IoT networks using machine learning-based feature selection and ensemble models*, desarrollaron una investigación aplicada sobre la gestión algorítmica ante la alta heterogeneidad del tráfico en sistemas IoT. Su protocolo metodológico consistió en acoplar modelos de ensamble clásicos, como Random Forest y Gradient Boosting, con rutinas selectivas de atributos. Los hallazgos revelaron que una discriminación óptima de variables permite a las arquitecturas mantener tasas de exactitud excepcionales garantizando baja demanda de hardware de procesamiento. Este trabajo consolida la viabilidad de utilizar algoritmos basados en árboles de decisión en ecosistemas restrictivos; no obstante, carece de evaluación sobre

conjuntos de ultra-alta dimensionalidad modernos, limitación que se superará al integrar el modelo con los 46 millones de flujos del CICIoT2023.

Alrayes et al. (2024), en *Intrusion Detection in IoT Systems Using Denoising Autoencoder*, desarrollaron una investigación aplicada enfocada en la seguridad para ecosistemas IoT sujetos a alta variabilidad y recursos limitados. Utilizaron Autoencoders de Eliminación de Ruido (DAE) basados en aprendizaje no supervisado para la extracción de características, validando el sistema con los conjuntos de datos CICIDS2017 y NSL-KDD. Los resultados exhibieron precisiones sobresalientes del 99.991 % y 99.4 % respectivamente, demostrando alta fiabilidad en procesamiento de eventos en tiempo real. Este trabajo resalta la relevancia de filtrar atributos para entornos de bajo consumo; sin embargo, su fundamentación en redes neuronales valida la propuesta de la presente tesis de integrar enfoques Stacking más ligeros para garantizar latencias de inferencia de rango inferior.

Berguiga et al. (2025), en *HIDS-IoMT: A Deep Learning-Based Intelligent Intrusion Detection System for the Internet of Medical Things*, plantearon un estudio experimental orientado a proteger redes de dispositivos médicos operando sobre arquitecturas computacionales de niebla. Metodológicamente combinaron redes convolucionales (CNN) y recurrentes (LSTM) para clasificar anomalías, ejecutando evaluaciones sobre los conjuntos de datos IoTID20 y Edge-IIoTset. Los hallazgos mostraron métricas críticas de Accuracy (99.92 %) y Recall (99.99 %) ante ataques disruptivos como denegación de servicio. Este antecedente subraya la robustez de los modelos híbridos para infraestructuras IoT de misión crítica; sin embargo, se enfoca primordialmente en ataques volumétricos mayores, dejando un área de oportunidad técnica en la identificación estricta de ataques minoritarios encubiertos.

Diwan et al. (2022), en su investigación *Feature Entropy Estimation (FEE) for Malicious IoT Traffic and Detection Using Machine Learning*, condujeron un estudio cuantitativo orientado a mejorar la identificación de actividades anómalas en volúmenes masivos de tráfico de red. La metodología propuesta consistió en utilizar la estimación de entropía para la ingeniería de características, evaluando algoritmos como XGBoost y Random Forest sobre el conjunto de datos Bot-IoT. Los hallazgos confirmaron que el uso de la entropía para discriminar atributos permite a los modelos alcanzar una precisión superior al

97% en la clasificación de amenazas. Este antecedente resulta fundamental para justificar el uso de la entropía de Shannon; no obstante, su enfoque no aborda la mitigación del desbalance extremo de clases, requerimiento que será subsanado.

Ferrag et al. (2022), en su artículo *Edge-IIoTset: A New Comprehensive Realistic Cyber Security Dataset of IoT and IIoT Applications for Centralized and Federated Learning*, ejecutaron un diseño experimental con el objetivo de proponer y validar un nuevo conjunto de datos representativo de amenazas modernas. Metodológicamente, generaron perfiles de tráfico desde múltiples dispositivos físicos, extrayendo características correlacionadas para evaluar el rendimiento de algoritmos tradicionales y enfoques profundos. Los resultados evidenciaron que los modelos predictivos estándar presentan severas limitaciones de exactitud cuando se enfrentan a escenarios realistas de intrusión. La relevancia de este estudio estriba en demostrar la insuficiencia de los clasificadores individuales ante la complejidad del tráfico, justificando la necesidad de implementar metamodelos robustos.

Gutierrez et al. (2023), en *Enhancing Intrusion Detection in IoT Communications Through ML Model Generalization With a New Dataset (IDSAI)*, ejecutaron una investigación aplicada destinada a cuantificar la capacidad de generalización en modelos de aprendizaje supervisado. La metodología introdujo el dataset normado y balanceado IDSAI para entrenar Random Forest, Gradient Boosting y XGBoost, validándolos posteriormente sobre el dataset externo Bot-IoT. Los hallazgos confirmaron a XGBoost como el modelo de mayor eficacia interna (94.97%), preservando un desempeño notable frente a datos externos no contemplados. Este artículo cimenta la elección de XGBoost por su alta resiliencia predictiva; no obstante, al utilizar un entorno pre-balanceado, omite el tratamiento del desbalance de tráfico real que abordará la presente tesis.

Kouassi et al. (2025a), en *Optimized Intrusion Detection in the IoT Through Statistical Selection and Classification with CatBoost and SNN*, condujeron un estudio cuantitativo orientado a mejorar la detección de anomalías abordando directamente el problema del desbalance de clases. En su marco metodológico, aplicaron técnicas de remuestreo como SMOTE y RUS de forma conjunta con regresión LASSO, validando la arquitectura CatBoost en el dataset IoTID20. Los resultados indican que la configuración híbrida maximiza el rendimiento, logrando una precisión de 82.43% y un F1-Score de 85.08%. El

estudio demuestra empíricamente la imperatividad del rebalanceo previo al entrenamiento; sin embargo, evalúa arquitecturas alternativas en un dataset de menor dimensionalidad que el CICIoT2023, brecha técnica que será suplida por el presente proyecto.

Kouassi et al. (2025b), en Top-K Feature Selection for IoT Intrusion Detection: Contributions of XGBoost, LightGBM, and Random Forest, desarrollaron una investigación aplicada orientada a reducir la carga computacional algorítmica en entornos IoT. Emplearon el dataset CICIoMT2024 aplicando una selección estadística Top-K sobre clasificadores supervisados, restringiendo las variables a las 10 y 15 más relevantes. Los hallazgos demostraron que el algoritmo Random Forest con Top-10 alcanzó un Accuracy de 91.7% y un F1-Score de 93%, reduciendo el tiempo de procesamiento en un 35%. Este estudio corrobora la pertinencia de la selección de características; no obstante, su enfoque en clasificadores individuales deja un vacío respecto a la capacidad predictiva de las arquitecturas Stacking.

Lin et al. (2021), en el documento Ensemble Learning for Threat Classification in Network Intrusion Detection on a Security Monitoring System for Renewable Energy, desarrollaron una investigación applied para categorizar amenazas informáticas mediante esquemas de aprendizaje por ensamble. En su metodología, contrastaron el rendimiento de algoritmos basados en árboles de decisión frente a modelos de Gradient Boosting como XGBoost, procesando registros de tráfico de red para identificar anomalías. Los resultados comprobaron que los enfoques de ensamble garantizan una alta precisión y sensibilidad en la detección. Este antecedente consolida la viabilidad técnica de integrar algoritmos como XGBoost para tareas de clasificación crítica; sin embargo, presenta una oportunidad técnica para extender y optimizar esta arquitectura hacia ecosistemas IoT con la técnica SMOTE.

Musthafa et al. (2024), en Optimizing IoT Intrusion Detection Using Balanced Class Distribution, Feature Selection, and Ensemble Machine Learning Techniques, realizaron un estudio cuantitativo orientado a optimizar la fiabilidad de los sistemas de detección. La metodología consistió en implementar arquitecturas Stacking con LSTM, aplicando un balanceo de clases y selección de características sobre los conjuntos UNSW-NB15 y NSL-KDD. Los hallazgos indican que la configuración Stacking con filtrado estadístico

alcanza una precisión de hasta 99.77%, mitigando significativamente el sobreajuste. Este artículo fundamenta empíricamente que la sinergia entre rebalanceo y Stacking maximiza el rendimiento predictivo; no obstante, la utilización de Deep Learning conlleva una alta carga computacional que la presente tesis evitará mediante algoritmos ligeros.

Nigar y Mustafa (2025), en *Enhanced Intrusion Detection via Hybrid Data Resampling and Feature Optimization*, elaboraron un diseño experimental combinando técnicas de optimización de atributos y sobremuestreo para estabilizar algoritmos predictivos. La metodología integró el algoritmo SMOTE para mitigar el desbalance previo al entrenamiento de ensambles modernos, particularmente XGBoost y LightGBM. Los resultados arrojaron que este preprocesamiento conjunto reduce significativamente el ratio de falsos positivos y proporciona alta estabilidad analítica frente a vectores de ataque de día cero. Este estudio proporciona un respaldo metodológico robusto; sin embargo, no contempla metadatos de incertidumbre lógica (entropía) para asistir la predicción, confirmando el vacío técnico que resolverá la presente propuesta de Stacking.

Popoola et al. (2025), en *Multi-Stage Deep Learning for Intrusion Detection in Industrial Internet of Things*, propusieron una investigación aplicada para resolver la identificación de ataques en entornos IIoT altamente desbalanceados. Su metodología incorporó un enfoque de aprendizaje profundo multi-etapa que utiliza la métrica de entropía para discriminar la incertidumbre predictiva, evaluado en los datasets X-IIOTID y WUSTL-IIoT. Los resultados evidenciaron métricas de precisión superiores al 99%, constatando que la cuantificación de la incertidumbre facilita la detección de intrusiones complejas y poco frecuentes. Este antecedente fundamenta teóricamente el uso de la entropía de Shannon en el metamodelo propuesto; no obstante, motiva el diseño de una solución más ligera basada en Stacking.

Sama et al. (2025), en su artículo *Cutting-Edge Intrusion Detection in IoT Networks: A Focus on Ensemble Models*, ejecutaron un estudio cuantitativo cuyo objetivo fue optimizar la detección de intrusiones mediante modelos de ensamble. Metodológicamente, emplearon datasets masivos de tráfico de red para evaluar la arquitectura híbrida Stacking, combinando XGBoost y LightGBM junto con métricas de incertidumbre (entropía). Los resultados evidenciaron que este modelo supera estadísticamente a los clasificadores

individuales en las métricas de Accuracy y Recall, minimizando simultáneamente las falsas alarmas. Este antecedente sustenta empíricamente la superioridad del ensamble propuesto; sin embargo, no aborda el desbalance extremo de datos, justificando la inclusión de la técnica Borderline-SMOTE en la presente investigación.

Sayegh et al. (2024), en Enhanced Intrusion Detection with LSTM-Based Model, Feature Selection, and SMOTE for Imbalanced Data, realizaron un estudio cuantitativo orientado a elevar las tasas de detección mitigando el sesgo algorítmico. La metodología integró el remuestreo SMOTE con selección de características RFE, evaluando el desempeño en datasets heterogéneos (CIC-IDS2017, NSL-KDD, UNSW-NB15). Los resultados confirmaron que la aplicación de SMOTE incrementa drásticamente la capacidad de detección, alcanzando precisiones pico de 99.34%. Este estudio sustenta la eficacia innegable del sobremuestreo sintético; no obstante, emplea una variante estándar, lo que justifica la implementación metodológica de Borderline-SMOTE para focalizar la generación de datos.

Sepúlveda-Fontaine y Amigó (2024), en el estudio teórico Applications of Entropy in Data Analysis and Machine Learning: A Review, condujeron una investigación documental con el objetivo de sistematizar el uso de medidas entrópicas en la optimización algorítmica. Metodológicamente, revisaron la aplicación de la entropía de Shannon como un funcional axiomático para caracterizar distribuciones de masa de probabilidad en el contexto de la minería de datos. Sus conclusiones determinaron que la entropía resulta excepcionalmente adecuada para evaluar la importancia de las características y medir el error en modelos predictivos. Este antecedente provee el sustento teórico y matemático necesario para justificar la integración de la Entropía de Shannon como parámetro de evaluación en el metamodelo propuesto.

Shanmugam et al. (2025), en Addressing Class Imbalance in Intrusion Detection: A Comprehensive Evaluation of Machine Learning Approaches, condujeron un estudio de diseño explicativo enfocado en evaluar rigurosamente el impacto de las estrategias de preprocesamiento. Emplearon métodos de rebalanceo algorítmico, como SMOTE y ADASYN, contrastados estadísticamente frente a diversos clasificadores estándar. Los resultados determinaron que el remuestreo incrementa drásticamente la tasa de detección de anomalías

infrecuentes sin degradar el rendimiento métrico en clases mayoritarias. Este antecedente resulta teóricamente vinculante con el presente proyecto al validar la necesidad ineludible del preprocesamiento para ataques minoritarios.

Wu et al. (2025), en MARNet: An Efficient Two-Stage Intrusion Detection Model Based on Deep Learning, diseñaron un estudio experimental para optimizar la identificación de vectores de ataque infrecuentes en redes informáticas. Emplearon los datasets UNSW-NB15 y NSL-KDD implementando la función de pérdida EQL v2 sobre redes neuronales residuales para mitigar el efecto negativo del desbalance de clases. La arquitectura propuesta alcanzó una precisión multiclase del 90.55 % y una tasa de detección del 99.51 %. Este artículo valida la criticidad de gestionar el desbalance para detectar intrusiones minoritarias; sin embargo, al emplear estructuras de Deep Learning, presenta limitaciones de viabilidad operativa que se abordarían empleando algoritmos de ensamble.

Zwane et al. (2019), en Ensemble Learning Approach for Flow-based Intrusion Detection System, ejecutaron un estudio experimental destinado a mejorar el análisis de flujos de red mediante métodos predictivos compuestos. En su diseño metodológico, evaluaron técnicas de ensamble probabilísticas y no probabilísticas basadas en árboles de decisión para clasificar intrusiones. Los resultados establecieron que los métodos de ensamble superan sistemáticamente a los algoritmos simples en capacidad de generalización sobre el tráfico anómalo. Aunque este estudio sienta las bases fundamentales para el uso de arquitecturas combinadas, su análisis carece de mecanismos específicos para tratar ataques de baja frecuencia, brecha metodológica que resolverá el enfoque híbrido propuesto.

2.1.2. Antecedentes nacionales

Raico Gallardo (2025), en Desarrollo de un modelo de clasificación para la detección de anomalías en redes IoT utilizando el dataset CICIOT2023, desarrolló un estudio aplicado de enfoque cuantitativo con el fin de identificar patrones maliciosos en entornos de Internet de las Cosas. En su diseño metodológico, procesó una muestra de 7,829,178 registros del dataset CICIOT2023, evaluando algoritmos como Regresión Logística, Árboles de Decisión y Random Forest mediante la herramienta Scikit-learn. Los resultados determinaron que el modelo Random Forest alcanzó la mayor efectividad con un 98.63 % de

exactitud, consolidándose como una técnica robusta para la clasificación de tráfico. Si bien esta investigación valida la potencia del dataset que se utilizará en el presente estudio, se identifica un vacío en el tratamiento de ataques de baja frecuencia, una oportunidad que será abordada mediante la integración de Stacking y técnicas de sobremuestreo sintético.

Villarroel Enriquez (2025), en su tesis titulada Análisis dinámico de malware mediante algoritmos de detección basados en machine learning, ejecutó una investigación experimental orientada a fortalecer la seguridad en dispositivos móviles a través del análisis de comportamientos dinámicos. La metodología empleada consistió en la comparación de los algoritmos XGBoost, LightGBM y Random Forest, utilizando la frecuencia de llamadas al sistema como métrica principal. Los hallazgos principales destacaron que el algoritmo LightGBM superó a los demás con una precisión del 94.1 %, demostrando ser una herramienta eficiente para mitigar amenazas en tiempo real. Este antecedente es relevante pues valida el uso de LightGBM en el contexto nacional, aunque su enfoque en malware deja espacio para investigar su desempeño en la detección específica de intrusiones en redes IoT.

León et al. (2024), en el trabajo Sistema que alerta la presencia de anomalías en logs de equipos IoT para prevenir el acceso no autorizado, propusieron una solución tecnológica para la detección temprana de vulnerabilidades en infraestructuras conectadas. El método consistió en el desarrollo de un sistema autónomo capaz de analizar grandes volúmenes de logs de auditoría mediante scripts de Python. Los resultados evidenciaron una efectividad variable (65 % al 100 %) supeditada a la calidad y cantidad de los datos recolectados de los dispositivos. La relevancia de este estudio reside en su aplicación práctica en entornos IoT reales; no obstante, su análisis se limita a registros de eventos, lo que genera un vacío respecto al análisis de flujos de red que la presente investigación cubrirá.

Oblitas Mantilla y Escobedo Cárdenas (2024), en Prediction of PM2.5 and PM10 concentrations using XGBoost and LightGBM algorithms: A Case Study in Lima, Peru, realizaron un estudio cuantitativo aplicado a la predicción de variables ambientales complejas. Metodológicamente, los autores compararon el desempeño de XGBoost y LightGBM procesando series temporales masivas obtenidas en el distrito de San Borja. Los resultados demostraron que LightGBM ofrece una velocidad de entrenamiento superior y una mayor

precisión en el manejo de datos voluminosos. Aunque el dominio de aplicación es ambiental, este antecedente es fundamental porque proporciona el sustento técnico y la validez metodológica en el Perú para la selección de XGBoost y LightGBM como los pilares del modelo de ensamble propuesto en esta tesis.

Curioso Mercado y Gonza Callenova (2025), en Propuesta de modelo de detección de ransomware basado en Aprendizaje Automático, desarrollaron una investigación experimental con el objetivo de identificar ataques de secuestro de datos antes de su ejecución. La metodología se centró en el preprocesamiento de características de red y el entrenamiento de modelos de clasificación supervisada para distinguir tráfico legítimo de patrones de cifrado. Los hallazgos indicaron que la optimización de hiperparámetros permite reducir drásticamente los falsos negativos en amenazas críticas. Este estudio se conecta con la presente investigación al subrayar la importancia del Recall, pero deja pendiente la mejora en la detección de ataques minoritarios, aspecto que se resolverá con el enfoque híbrido planteado.

Concha Ramos (2024), en Detección de intrusos en la red basado en red neuronal convolucional y aprendizaje por transferencia, ejecutó un estudio de nivel maestría para analizar el rendimiento de arquitecturas de aprendizaje profundo frente a ataques emergentes. El diseño metodológico empleó el dataset UNSW-NB15 y aplicó técnicas de Transfer Learning sobre Redes Neuronales Convolucionales (CNN) para evitar el reentrenamiento constante. Los resultados arrojaron una precisión del 85.22%, concluyendo que estos modelos son adaptables pero computacionalmente exigentes. La importancia de este antecedente radica en que establece un punto de comparación donde los modelos de ensamble basados en árboles (como el propuesto en este proyecto) suelen ofrecer una mayor exactitud y menor latencia en redes IoT.

2.2. MARCO TEÓRICO

2.2.1. Internet de las Cosas (IoT)

2.2.1.1. Arquitectura distribuida y capas de red


El paradigma del Internet de las Cosas (IoT) representa un ecosistema de computación omnipresente compuesto por objetos físicos y nodos interconectados con capacidades de detección, procesamiento y comunicación autónoma (Berguiga et al., 2025; Ferrag et al., 2022). La arquitectura de referencia estandarizada por la Unión Internacional de Telecomunicaciones (ITU-T) y el IEEE se estructura formalmente en cuatro capas funcionales interdependientes:

1. Capa de Percepción (Sensado): Integrada por elementos de hardware de bajo nivel (sensores de temperatura, cámaras IP, actuadores domóticos, dispositivos biomédicos y microcontroladores). Su función principal radica en la adquisición continua de magnitudes del entorno físico y la conversión analógico-digital de datos (Alrayes et al., 2024).
2. Capa de Red y Transporte: Responsable de la encapsulación, direccionamiento y transmisión confiable de los paquetes de tráfico. Utiliza protocolos de transporte livianos (UDP, TCP) y esquemas de red orientados a la escasez de recursos como IPv6 sobre redes inalámbricas de área personal de baja potencia (6LoWPAN), CoAP (Constrained Application Protocol), MQTT (Message Queuing Telemetry Transport) y Zigbee (Ahmed et al., 2024).
3. Capa de Niebla y Borde (Edge/Fog Computing): Constituida por pasarelas de red (IoT Gateways), concentradores domóticos y servidores locales de borde. Esta capa proporciona capacidad de cómputo intermedia a baja latencia, actuando como un filtro de seguridad en tiempo real antes de enviar la información a la infraestructura central (Berguiga et al., 2025).

4. Capa de Aplicación y Nube: Entorno de computación centralizado donde se ejecutan plataformas de almacenamiento masivo (*Big Data*), cuadros de mando empresarial y modelos analíticos de horizonte temporal extendido.

Figura 2.1

Arquitectura distribuida de cuatro capas funcionales en entornos IoT



2.2.1.2. Dispositivos de borde y pasarelas IoT (IoT Gateways)

En la capa de borde (Edge/Fog Computing), las pasarelas de red (IoT Gateways) operan como nodos concentradores y puntos de inspección obligatorios (Ferrag et al., 2022). Dado que estos dispositivos agregan el tráfico de docenas de micro-nodos y convierten protocolos heterogéneos a tramas Ethernet/IP estándar, constituyen la posición estratégica idónea para desplegar Sistemas de Detección de Intrusiones (IDS) locales (Alrayes et al., 2024; Raico Gallardo, 2025). El procesamiento local en pasarelas evita el costo operativo de transmitir gigabytes de tráfico sin filtrar hacia la nube, garantizando resiliencia funcional ante la pérdida eventual de conectividad a Internet.

2.2.1.3. Restricciones computacionales, de memoria y latencia

A pesar de su criticidad estratégica, las pasarelas y nodos de borde en entornos IoT exhiben restricciones de hardware severas que condicionan la elección del modelo analítico (Ahmed et al., 2024; Almotairi et al., 2024):

1. Memoria RAM acotada: Las pasarelas de borde industriales y comerciales disponen de memorias volátiles limitadas (típicamente entre 512 MB y 4 GB de RAM). Las arquitecturas de aprendizaje profundo masivas (como CNNs complejas o Transformers de redes) superan este umbral provocando fallos por memoria insuficiente (Out-Of-Memory).
2. Capacidad de procesamiento CPU: Microprocesadores integrados (arquitecturas ARM Cortex v7/v8 o x86 de bajo consumo) de baja frecuencia de reloj, lo que exige algoritmos de baja complejidad temporal $\mathcal{O}(N \log N)$.
3. Presupuesto de latencia ultrabaja: En la gestión de tráfico de red, la clasificación de cada flujo debe resolverse en microsegundos (μs). Una latencia elevada provocaría congestión de búferes y pérdida masiva de paquetes legítimos (Kouassi et al., 2025b).

2.2.1.4. Protocolos de comunicación de transporte (TCP/IP vs. UDP)

El comportamiento del tráfico de red en IoT está fuertemente condicionado por la elección del protocolo del nivel de transporte (Adewole et al., 2025). Mientras que el protocolo TCP (Transmission Control Protocol) garantiza la entrega mediante apretones de manos de tres vías (Three-Way Handshake) y control de flujo, el protocolo UDP (User Datagram Protocol) prioriza la velocidad y la baja latencia sin confirmación de recepción. Esta dicotomía es explotada por los ciberatacantes: los ataques volumétricos emplean inundaciones UDP o SYN para agotar la memoria de estados, mientras que los ataques a nivel de aplicación emplean sesiones TCP establecidas para inyectar vectores maliciosos de baja frecuencia (Ferrag et al., 2022).

2.2.2. Ciberseguridad y Detección de Intrusiones

2.2.2.1. Sistemas de Detección de Intrusiones (IDS)

Un Sistema de Detección de Intrusiones (IDS) es un mecanismo de defensa en profundidad diseñado para analizar continuamente el flujo de paquetes de red, identificando patrones anómalos, firmas de ataque o desviaciones de la conducta normal (Adewole et al., 2025; Musthafa et al., 2024). Los IDS se clasifican operacionalmente en dos categorías:

- IDS Basados en Firmas (Signature-based IDS): Comparan el tráfico entrante contra reglas estáticas conocidas (como Snort o Suricata). Son ineficaces frente a ataques emergentes o variaciones de día cero (*Zero-Day*).
- IDS Basados en Anomalías y Machine Learning (Anomaly-based IDS): Construyen modelos estadísticos y probabilísticos a partir de datos históricos, permitiendo generalizar y detectar patrones anómalos nunca antes vistos.

2.2.2.2. Arquitecturas NIDS vs. HIDS

Atendiendo a la ubicación de despliegue, la literatura distingue entre Sistemas de Detección de Intrusiones Basados en Host (HIDS - Host Intrusion Detection System), que inspeccionan llamadas al sistema y logs de auditoría en un único dispositivo; y Sistemas de Detección de Intrusiones Basados en Red (NIDS - Network Intrusion Detection System), los cuales analizan la cabecera y las métricas estadísticas de las ráfagas de paquetes que atraviesan los enlaces de comunicación (Berguiga et al., 2025). La presente tesis se posiciona en el paradigma NIDS, inspeccionando vectores de atributos estadísticos extraídos de los flujos IP.

2.2.2.3. Caracterización del tráfico con el dataset CICIoT2023

El desarrollo y validación experimental de esta investigación se fundamenta en el conjunto de datos estandarizado internacional CICIoT2023, publicado por el Canadian Institute for Cybersecurity (Adewole et al., 2025; Raico Gallardo, 2025). Este dataset fue diseñado capturando la actividad en una topología física real compuesta por 33 dispositivos

IoT (cámaras IP, altavoces domóticos, sensores, concentradores) sometidos a 33 vectores de ciberataque ejecutados bajo escenarios realistas.

El espacio vectorial original comprende 47 características estadísticas de red. Tras el proceso de selección de atributos por impureza de Gini e Información Mutua, el espacio de entrada se redujo a $d = 29$ variables continuas (tasas de paquetes por segundo, duración de flujos, tiempo entre llegadas, tamaño de cabeceras, indicadores de bandera TCP, varianza de tamaño de paquete, entre otros). El espacio categórico de salida se define como el conjunto de 8 clases de tráfico:

$$\mathcal{Y} = \{\text{Benign, Brute Force, DDoS, DoS, Mirai, Reconnaissance, Spoofing, Web-based}\} \quad (2.1)$$

2.2.2.4. Taxonomía de ciberataques: Volumétricos vs. Minoritarios

Desde la perspectiva de la distribución cuantitativa del volumen de tráfico, los ataques cibernéticos se dividen en dos grandes familias taxonómicas (Ferrag et al., 2022; Nigar & Mustafa, 2025):

1. Ataques Volumétricos Dominantes (DDoS, DoS, Mirai Botnet): Caracterizados por la emisión masiva de ráfagas de datos diseñadas para saturar la capacidad de procesamiento de la red. Representan el 95,53% de los registros anómalos del dataset CICIoT2023. Incluyen inundaciones UDP (UDP Flood), inundaciones SYN (TCP SYN Flood), inundaciones ICMP y ataques distribuidos coordinados por botnets infectadas como Mirai.
2. Ataques Minoritarios Infrecuentes y Sigilosos (Web-based, Brute Force, Reconnaissance): Caracterizados por secuencias extremadamente reducidas en número de paquetes ($< 0,5\%$ del volumen global) pero con un grado de amenaza destructiva crítico:
 - Web-based Attacks: Inyecciones SQL (SQLi), ejecución remota de comandos (Command Injection) y secuencias de comandos entre sitios (XSS) dirigidas a interfaces web de gestión en dispositivos domóticos.

- Brute Force Attacks: Intentos automatizados y sistemáticos de adivinación de credenciales sobre servicios de acceso remoto SSH y Telnet.
- Reconnaissance: Escaneo de puertos abiertos (*PortScan*) y análisis de huella digital de sistemas operativos (*OS Fingerprinting*) para descubrir vulnerabilidades explotables.

2.2.3. Desbalance de Datos y Preprocesamiento

2.2.3.1. Teorema del No Free Lunch y Desbalance de Clases

En la Teoría del Aprendizaje Estadístico, el Teorema del *No Free Lunch* (Wolpert, 1996) establece que ningún algoritmo de clasificación es universalmente superior sobre todas las distribuciones de probabilidad posibles. Cuando la distribución a priori de las clases objetivo $P(Y = k)$ presenta una asimetría extrema, los algoritmos supervisados convencionales colapsan en su capacidad discriminativa (Shanmugam et al., 2025).

2.2.3.2. Índice de Desbalance (Imbalance Ratio - IR)

Sea $S_k = \{x_i \in D \mid y_i = k\}$ el subconjunto de instancias pertenecientes a la categoría $k \in \mathcal{Y}$. El Índice de Desbalance (Imbalance Ratio - IR) mide formalmente la desproporción cuantitativa entre la clase más frecuente y la menos frecuente (Kouassi et al., 2025a):

$$\text{IR} = \frac{\max_{k \in \mathcal{Y}} |S_k|}{\min_{k \in \mathcal{Y}} |S_k|} \quad (2.2)$$

En el conjunto de prueba aislado de la investigación ($N_{\text{test}} = 377,383$ muestras), la clase mayoritaria DDoS registra $|S_{\text{DDoS}}| = 148,475$ observaciones, mientras que la clase minoritaria crítica Web-based cuenta con apenas $|S_{\text{Web-based}}| = 3,556$ observaciones, arrojando un ratio extremo de:

$$\text{IR} = \frac{148,475}{3,556} \approx 41,75 \quad (2.3)$$

2.2.3.3. Sesgo algorítmico y Paradoja de la Exactitud (Accuracy Paradox)

Durante la fase de optimización de los parámetros del modelo, los clasificadores supervisados buscan minimizar la función de pérdida empírica global:

$$\mathcal{L}_{\text{emp}}(f) = \frac{1}{N} \sum_{i=1}^N l(y_i, f(x_i)) \quad (2.4)$$

Dado que el 95 % de las observaciones pertenecen a clases volumétricas mayoritarias, los gradientes de actualización del error están dominados casi exclusivamente por dichas instancias (Wu et al., 2025). Como resultado, el clasificador desplaza su hiperplano de decisión hacia la región de las clases minoritarias, clasificando erróneamente casi todas las muestras de Web-based y Brute Force como tráfico benigno o DoS. Esto desencadena la denominada Paradoja de la Exactitud (Accuracy Paradox): el sistema reporta una exactitud global falsamente elevada ($> 84\%$) simplemente por predecir correctamente las clases volumétricas, pese a presentar una sensibilidad prácticamente nula ($Recall \rightarrow 0$) en la detección de los ataques infrecuentes más peligrosos (Nigar & Mustafa, 2025).

2.2.3.4. Escalado Robusto Adaptativo (RobustScaler)

El tráfico de red en entornos IoT se caracteriza por presentar distribuciones estadísticas fuertemente sesgadas y ráfagas extremas de valores atípicos (outliers) provocadas por los ataques volumétricos. La aplicación de técnicas de escalado tradicionales resulta inapropiada (Curioso & Gonza, 2025):

- StandardScaler (Z-Score): Fundado en la media aritmética μ_j y la desviación estándar σ_j , métricas extremadamente sensibles a valores atípicos que distorsionan el rango transformado.
- MinMaxScaler: Comprime los valores al intervalo $[0, 1]$ utilizando el mínimo y máximo absoluto, lo cual provoca que las ráfagas extremas colapsen el 99% de los datos normales en un rango diminuto cercano a cero.

Para mitigar esta distorsión sin descartar información real, se aplica el algoritmo RobustScaler, el cual sustituye los momentos estadísticos por la Mediana (Q_2) y el Rango

Intercuartílico ($\text{IQR} = Q_3 - Q_1$) (Al-Emari et al., 2024):

$$x_{ij}^{\text{scaled}} = \frac{x_{ij} - Q_2(x_j)}{Q_3(x_j) - Q_1(x_j)} = \frac{x_{ij} - \text{Mediana}(x_j)}{\text{IQR}(x_j)} \quad (2.5)$$

En caso de que el rango sea nulo ($\text{IQR}_j = 0$), se asigna $\text{IQR}_j = 1,0$ para evitar indeterminaciones matemáticas por división sobre cero.


2.2.3.5. Sobremuestreo Sintético en la Frontera (Borderline-SMOTE1)

Para resolver el desbalance de clases sin incurrir en pérdida de información por submuestreo aleatorio (RUS), la literatura propone técnicas de sobremuestreo sintético (Sayegh et al., 2024; Shanmugam et al., 2025). No obstante, el algoritmo SMOTE convencional genera muestras sintéticas en todo el espacio minoritario de forma no discriminativa, lo que suele introducir ruido en el interior de la región de la clase mayoritaria.

Para superar esta limitación, el algoritmo Borderline-SMOTE1 (Nigar & Mustafa, 2025) restringe la generación sintética exclusivamente a aquellas instancias minoritarias que se ubican en la franja limítrofe o zona de peligro de decisión (S_{danger}).

Figura 2.2

Topología de frontera y generación sintética de instancias con Borderline-SMOTE1



El procedimiento computacional de Borderline-SMOTE1 opera secuencialmente en tres etapas sobre las muestras minoritarias S_{min} :

1. Cálculo de Vecindad Euclidiana: Para cada instancia minoritaria $x_i \in S_{\text{min}}$, se determinan sus m vecinos más cercanos en el conjunto completo de entrenamiento

mediante la distancia Euclidiana:

$$d(x_i, x_j) = \sqrt{\sum_{l=1}^d (x_{il} - x_{jl})^2} \quad (2.6)$$

2. Clasificación Topológica de Instancias: Se contabiliza el número de vecinos m_v pertenecientes a la clase mayoritaria S_{maj} :

- Si $m_v = m$, todos los vecinos son mayoritarios; la muestra se considera ruido aislado y no se sobremuestra.
- Si $0 \leq m_v < m/2$, la mayoría de los vecinos son minoritarios; la muestra está segura en el interior de su conglomerado (S_{safe}) y no requiere intervención.
- Si $m/2 \leq m_v < m$, la muestra está rodeada predominantemente por la clase mayoritaria; se clasifica como punto limítrofe en peligro ($x_i \in S_{\text{danger}}$).

3. Interpolación Sintética en la Frontera: Para cada $x_i \in S_{\text{danger}}$, se identifican sus k vecinos más cercanos pertenecientes únicamente a la clase minoritaria S_{min} . Se selecciona aleatoriamente un vecino x_{zi} y se genera una nueva observación sintética x_{new} mediante la fórmula de interpolación lineal:

$$x_{\text{new}} = x_i + \delta \cdot (x_{zi} - x_i), \quad \delta \sim U(0, 1) \quad (2.7)$$

donde δ es un escalar aleatorio generado desde una distribución uniforme continua en el intervalo $[0, 1]$.

2.2.4. Algoritmos de Aprendizaje Automático Base (Nivel 0)

2.2.4.1. Teoría de Ensamble y Compromiso Sesgo-Varianza

En el marco del aprendizaje supervisado, el error cuadrático medio de un estimador se descompone axiomáticamente como:

$$\text{Error}(f) = \text{Sesgo}^2(f) + \text{Varianza}(f) + \sigma_{\text{ruido}}^2 \quad (2.8)$$

Los clasificadores individuales simples suelen sufrir de alto sesgo (subajuste) o alta varianza (sobreajuste). Los métodos de ensamble (*Ensemble Learning*) combinan múltiples clasificadores base para reducir simultáneamente la varianza (mediante *Bagging*) y el sesgo (mediante *Gradient Boosting*), alcanzando un compromiso óptimo (Zwane et al., 2019; Almotairi et al., 2024).

2.2.4.2. Random Forest (Bagging e Impureza de Gini)

Random Forest (Breiman, 2001; Almotairi et al., 2024; Kouassi et al., 2025b; Raico Gallardo, 2025) es una arquitectura de ensamble basada en *Bagging* (*Bootstrap Aggregating*). Construye $M = 100$ árboles de decisión no correlacionados $\{h_m(x)\}_{m=1}^M$ entrenados sobre submuestras aleatorias obtenidas por remuestreo con reemplazo.

Para descorrelacionar los árboles, en cada división de nodo el algoritmo no evalúa la totalidad de las d características, sino un subconjunto restringido de $m_{\text{try}} = \sqrt{d} = \sqrt{29} \approx 5$ atributos seleccionados al azar. La probabilidad predicha para la clase $k \in \{0, \dots, 7\}$ es el promedio simple de las probabilidades emitidas por cada árbol individual:

$$P_{\text{RF}}(Y = k|x) = \frac{1}{M} \sum_{m=1}^M P_{h_m}(Y = k|x) \quad (2.9)$$

La selección de la mejor división en cada nodo se guía por la maximización de la ganancia de Impureza de Gini:

$$I_G(p) = 1 - \sum_{k=0}^{K-1} p_k^2 \quad (2.10)$$

donde p_k representa la proporción de instancias pertenentes a la clase k en el nodo evaluado.

2.2.4.3. XGBoost GPU (Gradient Boosting regularizado de 2º orden)

XGBoost (*Extreme Gradient Boosting*) (Chen & Guestrin, 2016; Adewole et al., 2025; Gutierrez et al., 2023; Oblitas & Escobedo, 2024) es un algoritmo de Gradient Boosting aditivo que construye árboles de decisión secuencialmente. En cada iteración t ,

el nuevo árbol $f_t(x)$ se añade para minimizar la siguiente función objetivo regularizada:

$$\mathcal{L}^{(t)} = \sum_{i=1}^N l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t) \quad (2.11)$$

donde el término de regularización L1/L2 $\Omega(f_t)$ penaliza la complejidad estructural del árbol:

$$\Omega(f_t) = \gamma T_{\text{hojas}} + \frac{1}{2} \lambda \sum_{j=1}^{T_{\text{hojas}}} w_j^2 \quad (2.12)$$

siendo T_{hojas} el número de hojas terminales y w_j el peso asignado a cada hoja.

A diferencia del Gradient Boosting clásico, XGBoost aproxima la función objetivo mediante la expansión de la serie de Taylor de segundo orden:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^N \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (2.13)$$

donde los términos de primer y segundo orden corresponden al gradiente g_i y al Hessiano h_i :

$$g_i = \frac{\partial l(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}}, \quad h_i = \frac{\partial^2 l(y_i, \hat{y}_i^{(t-1)})}{\partial (\hat{y}_i^{(t-1)})^2} \quad (2.14)$$

Para acelerar masivamente el procesamiento de los 2.51 millones de registros, XGBoost se ejecuta en la GPU NVIDIA RTX 5070 Ti mediante el método de construcción de histogramas cuantizados en memoria gráfica (`tree_method='hist', device='cuda'`).

2.2.4.4. LightGBM (Crecimiento por hojas Leaf-wise, GOSS y EFB)

LightGBM (*Light Gradient Boosting Machine*) (Ke et al., 2017; Al-Emari et al., 2024; Oblitas Mantilla & Escobedo Cárdenas, 2024; Villarroel Enriquez, 2025) es un marco de trabajo de Gradient Boosting diseñado para ofrecer alta velocidad y eficiencia en memoria. Presenta tres innovaciones arquitectónicas:

1. Estrategia de Crecimiento por Hojas (Leaf-Wise Growth): En lugar de expandir los árboles nivel por nivel de forma simétrica (*Level-Wise*), LightGBM busca y expande de forma codiciosa la hoja con la mayor ganancia de pérdida esperada (*delta loss*), fijando un límite de profundidad (`max_depth=6`) para evitar sobreajuste.

2. GOSS (Gradient-Based One-Side Sampling): Ordena descendientemente las instancias según el valor absoluto de su gradiente $|g_i|$. Conserva el 100% de las observaciones con gradientes grandes (las más difíciles de clasificar) y realiza un muestreo aleatorio uniforme sobre las instancias con gradientes pequeños, multiplicando a estas últimas por un factor de compensación para mantener la distribución original.
3. EFB (Exclusive Feature Bundling): Empaqueta variables dispersas que son mutuamente excluyentes (es decir, que rara vez toman valores distintos de cero simultáneamente) en un menor número de características densas, reduciendo la complejidad espectral del problema.

Las probabilidades multiclase $P_{\text{LGB}}(Y = k|x)$ se obtienen aplicando la función de activación Softmax sobre las puntuaciones continuas $F_k(x)$:

$$P_{\text{LGB}}(Y = k|x) = \frac{\exp(F_k(x))}{\sum_{j=0}^{K-1} \exp(F_j(x))} \quad (2.15)$$

2.2.5. Cuantificación de Incertidumbre Predictiva

2.2.5.1. Teoría de la Información de Shannon

La Teoría de la Información desarrollada axiomáticamente por Claude Shannon (1948) provee las bases matemáticas para cuantificar la cantidad de incertidumbre, entropía e información contenida en una variable aleatoria discreta (Sepúlveda-Fontaine & Amigó, 2024).

2.2.5.2. Entropía de Shannon como métrica de ambigüedad predictiva

En el contexto de la clasificación multiclase, cuando un clasificador base $m \in \{\text{RF}, \text{XGB}, \text{LGB}\}$ evalúa un flujo de red x , emite un vector discreto de probabilidades $\mathbf{P}_m(x) = [p_0, p_1, \dots, p_7] \in \mathbb{R}^8$, donde $\sum_{k=0}^7 p_k = 1, 0$.

La Entropía de Shannon $H_m(x)$ mide la incertidumbre o dispersión lógica inherente a dicha distribución (Diwan et al., 2022; Popoola et al., 2025; Sama et al., 2025):


$$H_m(x) = - \sum_{k=0}^{K-1} P_m(Y = k|x) \log_2 (P_m(Y = k|x) + \varepsilon) \quad (2.16)$$

donde $\varepsilon = 10^{-15}$ es una constante infinitesimal agregada para garantizar estabilidad numérica y prevenir indeterminaciones por $\log_2(0)$.

Figura 2.3

Comportamiento de la Entropía de Shannon según la dispersión del vector de probabilidad

Entropía de Shannon $H(x)$ (bits)



Las propiedades funcionales de la Entropía de Shannon son:

- Certeza Absoluta ($H_m(x) \rightarrow 0$ bits): Ocurre cuando el clasificador base asigna $p_k \approx 1,0$ a una sola clase y $p_j \approx 0,0$ a las restantes. Indica que el modelo está completamente seguro de su predicción.
- Ambigüedad Máxima ($H_m(x) \rightarrow \log_2(8) = 3,0$ bits): Ocurre cuando el modelo asigna una probabilidad equiprobable $p_k \approx 1/8 = 0,125$ a las 8 clases. Esta condición suele manifestarse en las regiones fronterizas entre tráfico benigno y vectores de ataque minoritarios infrecuentes, alertando formalmente al meta-clasificador sobre la zona de alta duda.

2.2.6. Arquitectura de Ensamble por Stacking Híbrido

2.2.6.1. Principios teóricos del Stacking (Stacked Generalization)

La arquitectura de ensamble por Stacking (*Stacked Generalization*) fue formulada por David Wolpert (1992) como un esquema de meta-aprendizaje diseñado para deducir qué clasificadores base son más confiables en qué regiones del espacio de características (Ahmed et al., 2024; Musthafa et al., 2024; Lin et al., 2021). A diferencia de los ensambles por *Voting* (voto mayoritario) o *Averaging* (promedio simple), Stacking entrena un modelo superior de Nivel 1 (*Meta-Modelo*) que aprende a combinar de forma no lineal las salidas probabilísticas de los modelos de Nivel 0.

2.2.6.2. Generación de Meta-características fuera de pliegue (OOF)

Un desafío metodológico crítico en las arquitecturas Stacking es la prevención de la Fuga de Datos (*Data Leakage*) y el sobreajuste (*Overfitting*). Si el meta-modelo se entrena utilizando las predicciones generadas por los modelos de Nivel 0 sobre los mismos datos con los que fueron entrenados, el metamodelo memorizará el sesgo de los clasificadores primarios.

Para resolver este problema de forma científicamente rigurosa, las meta-características se construyen aplicando una validación cruzada estratificada fuera de pliegue (*Out-Of-Fold - OOF*) de $K = 3$ pliegues (Musthafa et al., 2024; Nigar & Mustafa, 2025):

1. El conjunto de entrenamiento D_{train} se particiona en 3 subconjuntos disjuntos estratificados.
2. En cada iteración $k \in \{1, 2, 3\}$, los clasificadores base (Random Forest, XGBoost GPU y LightGBM) se entrenan sobre 2 pliegues y emiten sus predicciones únicamente sobre el pliegue de validación retenido.
3. Se calculan las 3 entropías de Shannon instantáneas $H_{\text{RF}}, H_{\text{XGB}}, H_{\text{LGB}}$ sobre las probabilidades del pliegue retenido.

4. Se concatenan las 24 probabilidades predichas ($3 \text{ modelos} \times 8 \text{ clases}$) junto con las 3 métricas de entropía, formando la matriz de meta-características $Z_{\text{train}} \in \mathbb{R}^{N_{\text{train}} \times 27}$:

$$z_i = \left[P_{\text{RF}}(x_i), P_{\text{XGB}}(x_i), P_{\text{LGB}}(x_i), H_{\text{RF}}(x_i), H_{\text{XGB}}(x_i), H_{\text{LGB}}(x_i) \right] \in \mathbb{R}^{27} \quad (2.17)$$

2.2.6.3. Meta-Modelo de Nivel 1 (LightGBM)

El meta-clasificador de Nivel 1 es una instancia optimizada de LightGBM que toma como espacio vectorial de entrada la matriz $Z \in \mathbb{R}^{27}$ (Ke et al., 2017; Villarroel Enriquez, 2025). Durante la fase de entrenamiento, el meta-modelo aprende patrones complejos de decisión; por ejemplo, si Random Forest presenta alta entropía ($H_{\text{RF}} > 2,5$) en un flujo específico, el meta-modelo otorga mayor ponderación a la predicción de XGBoost GPU o examina las probabilidades minoritarias residuales.

La sintonización fina de los hiperparámetros del meta-modelo se ejecutó mediante una búsqueda en malla con validación cruzada (`GridSearchCV`), fijando la combinación óptima: `n_estimators=100`, `learning_rate=0.05`, `num_leaves=31`, `max_depth=6`, `subsample=0.8` y `colsample_bytree=0.8`.

2.2.7. Métricas de Evaluación y Prueba Estadística

2.2.7.1. Métricas de clasificación multiclase

Dada la matriz de confusión de contingencia $K \times K$ ($K = 8$), para cada categoría $k \in \{0, \dots, 7\}$ se definen los parámetros de conteo: Verdaderos Positivos (TP_k), Falsos Positivos (FP_k), Verdaderos Negativos (TN_k) y Falsos Negativos (FN_k) (Kouassi et al., 2025b; Nigar & Mustafa, 2025).

A partir de estos valores se derivan las métricas estadísticas estándar:

1. Accuracy Global (Exactitud):

$$\text{Accuracy} = \frac{\sum_{k=0}^{K-1} TP_k}{\sum_{k=0}^{K-1} (TP_k + TN_k + FP_k + FN_k)} \quad (2.18)$$

2. Recall por Clase (Sensibilidad):

$$\text{Recall}_k = \frac{TP_k}{TP_k + FN_k} \quad (2.19)$$

3. Precision por Clase (Precisión):

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k} \quad (2.20)$$

4. F1-Score por Clase:

$$\text{F1-Score}_k = 2 \times \frac{\text{Precision}_k \times \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k} \quad (2.21)$$

5. F1-Macro (Métrica Primaria de Evaluación):

$$\text{F1-Macro} = \frac{1}{K} \sum_{k=0}^{K-1} \text{F1-Score}_k \quad (2.22)$$

El *F1-Macro* se establece como el indicador primario de la investigación debido a que calcula el promedio aritmético no ponderado entre las 8 clases. A diferencia de Accuracy, otorga exactamente la misma importancia cuantitativa (1/8) a la clase minoritaria crítica Web-based que a la clase mayoritaria hiper-dominante DDoS.

2.2.7.2. Perfilado de rendimiento computacional

Para evaluar la viabilidad operativa del modelo en pasarelas IoT de borde, se midieron empíricamente dos indicadores computacionales (Almotairi et al., 2024; Ahmed et al., 2024):

1. Latencia de Inferencia por Muestra (μs): Medida dividiendo el tiempo cronometrado total de inferencia sobre el conjunto de prueba aislado entre el número total de muestras ($N_{\text{test}} = 377,383$):

$$\text{Latencia} = \left(\frac{t_{\text{predict}}}{N_{\text{test}}} \right) \times 10^6 \mu s \quad (2.23)$$

2. Consumo de Memoria RAM (MB): Medido mediante perfilado de memoria RAM en tiempo real registrando el tamaño del proceso en megabytes durante la fase de carga e inferencia del modelo.

2.2.7.3. Prueba Estadística No Paramétrica de Wilcoxon

Para contrastar formalmente la Hipótesis General de la investigación y determinar si la mejora alcanzada por el Stacking Híbrido es estadísticamente significativa y no producto del azar, se aplicó la Prueba de Rangos con Signo de Wilcoxon (1945; Sama et al., 2025).

El conjunto de prueba aislado de 377,383 muestras se dividió en $N_b = 30$ bloques estratificados independientes de tamaño $n_b \approx 12,579$. Para cada bloque $j \in \{1, \dots, 30\}$, se calculó la diferencia empírica del *F1-Macro* entre el Stacking Híbrido propuesto (S) y cada modelo de control (B):

$$d_j = \text{F1-Macro}_S(j) - \text{F1-Macro}_B(j) \quad (2.24)$$

Se ordenan los valores absolutos $|d_j|$ asignándoles rangos R_j^+ . El estadístico de prueba W^+ suma los rangos positivos:

$$W^+ = \sum_{j:d_j > 0} R_j^+ \quad (2.25)$$

Se formulan las hipótesis estadísticas:

$$H_0 : \mu_d = 0 \quad (\text{No existe diferencia significativa en el rendimiento entre los modelos}) \quad (2.26)$$

$$H_1 : \mu_d > 0 \quad (\text{El Stacking Híbrido presenta un F1-Macro estadísticamente superior al modelo de control}) \quad (2.27)$$

Fijando un nivel de significancia $\alpha = 0,05$, si el p -valor resultante satisface $p < 0,05$, se rechaza H_0 aceptando la superioridad estadística de la propuesta con un 99,5% de confianza.

2.3. DEFINICIÓN DE TÉRMINOS BÁSICOS

Accuracy (Exactitud Global): Métrica estadística que cuantifica la proporción general de predicciones correctas (positivas y negativas) realizadas por el clasificador sobre el total de observaciones evaluadas en la prueba.

Algoritmo Base (Nivel 0): Modelo de aprendizaje automático primario (Random Forest, XGBoost GPU o LightGBM) que opera directamente sobre las variables preprocesadas para extraer vectores probabilísticos.

Ataque Minoritario: Categoría de ciberataque (como Web-based o Brute Force) que presenta una frecuencia cuantitativa extremadamente baja ($< 1\%$) dentro del volumen global del tráfico de red.

Bagging (Bootstrap Aggregating): Técnica de aprendizaje por ensamble que combina predicciones de múltiples estimadores entrenados de forma independiente sobre submuestras aleatorias generadas con reemplazo.

Borderline-SMOTE: Algoritmo de sobremuestreo adaptativo que enfoca la generación de instancias sintéticas exclusivamente en el subconjunto de muestras minoritarias ubicadas en la frontera de decisión.

Bootstrap: Método de remuestreo probabilístico con reemplazo que permite generar múltiples particiones sintéticas de entrenamiento de igual tamaño a partir de un conjunto original.

Botnet Mirai: Código malicioso que infecta dispositivos IoT vulnerables mediante credenciales por defecto, convirtiéndolos en bots bajo el control de un servidor de Comando y Control (C2).

Brute Force Attack (Ataque de Fuerza Bruta): Mecanismo de intrusión automatizado que prueba repetidamente combinaciones de nombres de usuario y contraseñas hasta vulnerar el control de acceso.

CICIoT2023: Dataset de ciberseguridad representativo desarrollado por el Canadian Institute for Cybersecurity que registra el tráfico real de 33 vectores de ataque en topologías IoT reales.

Data Leakage (Fuga de Datos): Error metodológico severo en el cual información del conjunto de prueba o validación se filtra involuntariamente en la etapa de entrenamiento o preprocesamiento.

Desbalance de Clases: Condición estructural de un conjunto de datos donde la distribución de frecuencias de las categorías objetivo exhibe una asimetría extrema.

Entropía de Shannon: Métrica axiomática de la Teoría de la Información que cuantifica la cantidad de incertidumbre o dispersión en la distribución de probabilidades predicha.

Exclusive Feature Bundling (EFB): Algoritmo de reducción de dimensionalidad de LightGBM que agrupa características mutuamente excluyentes para acelerar el entrenamiento.

F1-Macro: Métrica de evaluación obtenida mediante el promedio simple sin ponderar de los F1-Scores de cada categoría, priorizando el rendimiento en clases minoritarias.

F1-Score: Media armónica entre Precision y Recall, que evalúa el equilibrio entre la tasa de verdaderos positivos y la mitigación de falsos negativos.

Gini Impurity (Impureza de Gini): Medida de desorden empleada en árboles de decisión para evaluar la probabilidad de clasificar erróneamente un elemento seleccionado al azar.

Gradient-Based One-Side Sampling (GOSS): Técnica de muestreo inteligente de LightGBM que conserva las instancias con gradientes elevados y submuestra instancias con gradientes pequeños.

Gradient Boosting: Familia de algoritmos de ensamble secuencial que construyen árboles de decisión de forma aditiva minimizando la función de pérdida mediante el descenso de gradiente.

GridSearchCV: Protocolo de optimización de hiperparámetros que evalúa exhaustivamente un espacio discreto de combinaciones mediante validación cruzada.

Imbalance Ratio (IR): Razón matemática que mide la proporción directa entre el número de instancias de la clase dominante y la clase menos frecuente.

IoT Gateway (Pasarela IoT): Dispositivo de red intermedio encargado de conectar nodos IoT con la infraestructura de nube, procesando y filtrando flujos de datos de borde.

Latencia de Inferencia: Tiempo computacional exacto medido en microsegundos (μs) que requiere el modelo predictivo para evaluar y clasificar una muestra de tráfico.

Leaf-Wise Growth: Estrategia de división de árboles de decisión en LightGBM que expande la hoja con la mayor ganancia de pérdida esperada en lugar de dividir por niveles.

LightGBM: Marco de trabajo de Gradient Boosting ligero optimizado para alto rendimiento computacional, bajo uso de memoria y alta velocidad de procesamiento.

Matriz de Confusión: Tabla de contingencia de doble entrada que compara las etiquetas reales del conjunto de prueba con las predicciones generadas por el modelo.

Meta-Características (Meta-Features): Vector de atributos compuesto por las probabilidades predichas y las entropías calculadas de los modelos de Nivel 0 para alimentar el Nivel 1.

Meta-Modelo (Nivel 1): Clasificador superior en una arquitectura Stacking que aprende a combinar óptimamente las predicciones emitidas por los modelos de Nivel 0.

OOB Error (Error Out-Of-Bag): Métrica de validación interna en Random Forest calculada sobre las muestras de entrenamiento que no fueron seleccionadas en el bootstrap.

Out-Of-Fold (OOF): Protocolo de predicción fuera de pliegue mediante validación cruzada K -Fold que garantiza la generación de meta-features libres de sobreajuste.

Precision (Precisión): Proporción de observaciones clasificadas correctamente como positivas dentro del total de instancias predichas como positivas.

Prueba de Wilcoxon: Test estadístico no paramétrico de rangos con signo utilizado para determinar si existe una diferencia significativa entre las medianas de dos grupos emparejados.

Random Forest: Algoritmo de ensamble supervisado que combina múltiples árboles de decisión construidos aleatoriamente mediante Bagging.

Recall (Sensibilidad): Proporción de instancias verdaderamente positivas que fueron identificadas e inferidas correctamente por el modelo.

RobustScaler: Algoritmo de escalado numérico basado en la mediana y el rango intercuartílico (IQR), resistente a la influencia de valores atípicos severos.

Softmax: Función de activación matemática que convierte un vector de puntuaciones continuas numéricas en una distribución discreta de probabilidades normalizada.

Stacking (Stacked Generalization): Arquitectura jerárquica de ensamble donde uno o más meta-clasificadores se entrenan utilizando las predicciones de modelos base.

Web-based Attack: Vectores de ataque orientados a vulnerar aplicaciones web en dispositivos IoT, incluyendo inyecciones SQL, mando remoto y scripts entre sitios.

XGBoost (Extreme Gradient Boosting): Algoritmo altamente optimizado de Gradient Boosting que incorpora regularización L1/L2 y soporte nativo para computación en GPU.

CAPÍTULO III

MATERIALES Y MÉTODOS

3.1. DISEÑO METODOLÓGICO

3.1.1. Tipo de Investigación

La presente investigación se clasifica como de tipo Aplicada, dado que está orientada a la solución práctica, técnica e innovadora de un problema cibernético crítico en la infraestructura digital contemporánea: la severa degradación predictiva de los Sistemas de Detección de Intrusiones (IDS) convencionales ante ciberataques de baja frecuencia o minoritarios (Web-based y Brute Force) en redes del Internet de las Cosas (IoT).

Asimismo, posee un enfoque Cuantitativo, puesto que la eficacia predictiva y la viabilidad computacional de la arquitectura propuesta se miden de forma numérica, objetiva y probabilística a través de indicadores empíricos estandarizados (F1-Macro, Recall, Precision, Accuracy, latencia de inferencia en microsegundos μs y ocupación de memoria RAM en megabytes MB), validados mediante pruebas de hipótesis no paramétricas de significancia estadística.

3.1.2. Diseño de Investigación y Control de Variables

El diseño de investigación adoptado es Experimental, de nivel Cuasi-experimental con grupo de control equivalente. En un entorno de simulación computacional controlado a nivel de laboratorio, se manipula intencionalmente la Variable Independiente (la arquitectura híbrida Stacking integrada por Random Forest, XGBoost GPU y LightGBM con cuantificación de incertidumbre por Entropía de Shannon y sobremuestreo adaptativo Borderline-SMOTE1) para evaluar su efecto directo sobre la Variable Dependiente (la eficacia en la detección de ataques minoritarios y el desempeño computacional en redes IoT).

Para garantizar el rigor científico, la validez interna y el control de variables de confusión, el rendimiento de la arquitectura híbrida propuesto se contrasta empíricamente contra seis modelos de control independientes:

1. Random Forest individual sin rebalanceo.
2. XGBoost GPU individual sin rebalanceo.
3. LightGBM individual sin rebalanceo.
4. Random Forest con sobremuestreo Borderline-SMOTE1.
5. XGBoost GPU con sobremuestreo Borderline-SMOTE1.
6. LightGBM con sobremuestreo Borderline-SMOTE1.

3.1.3. Marco de Trabajo Metodológico: CRISP-DM Adaptado

La ejecución del proyecto sigue el marco de trabajo estándar internacional CRISP-DM (Cross-Industry Standard Process for Data Mining), estructurado de forma secuencial en 15 pasos computacionales distribuidos en 6 fases metodológicas:

Tabla 3.1


Fases metodológicas de CRISP-DM y su mapeo con los notebooks del proyecto

Fase CRISP-DM	Actividades y Pasos Metodológicos	Artefacto / Notebook
1. Comprensión del Negocio	Paso 1: Definición del problema de sesgo algorítmico y desbalance en redes IoT.	capitulos/introduccion.tex
2. Comprensión de los Datos	Paso 2: Ingesta de 63 archivos CSV de la página oficial de CICIOT2023. Paso 3: Análisis Exploratorio de Datos (EDA) y distribución de 8 clases.	notebooks/01_EDA.ipynb
3. Preparación de los Datos	Paso 4: Limpieza de valores nulos, infinitos y eliminación de duplicados. Paso 5: Escalado robusto adaptativo (RobustScaler). Paso 6: Selección de 29 variables por Gini e Información Mutua. Paso 7: Sobremuestreo adaptativo Borderline-SMOTE1 en entrenamiento.	notebooks/02_preprocesamiento.ipynb
4. Modelado de Nivel 0	Paso 8: Entrenamiento OOF 3-Fold de Random Forest, XGBoost GPU y LightGBM. Paso 9: Extracción de 24 probabilidades de clase. Paso 10: Cuantificación entrópica (H_{RF}, H_{XGB}, H_{LGB}) conformando $Z \in \mathbb{R}^{27}$.	notebooks/03_modelos_base.ipynb
5. Modelado de Nivel 1	Paso 11: Optimización del meta-modelo LightGBM con GridSearchCV. Paso 12: Ensamblado de la arquitectura Stacking Híbrida.	notebooks/04_modelo_hibrido.ipynb
6. Evaluación y Validación	Paso 13: Inferencia sobre el conjunto de prueba aislado (377,383 muestras). Paso 14: Perfilado de latencia (μs) y uso de memoria RAM (MB). Paso 15: Validación de significancia mediante la Prueba de Wilcoxon.	notebooks/05_resultados_finales.ipynb

Nota. Diseñado conforme a las fases del ciclo de vida del modelo computacional.

Figura 3.1

Flujo metodológico CRISP-DM adaptado a la investigación



3.2. UNIDADES DE ANÁLISIS, POBLACIÓN Y MUESTRA

3.2.1. Población Objetivo y Procedencia del Dataset

La población de estudio comprende la totalidad de flujos de paquetes de red generados en la topología física real del conjunto de datos internacional CICIOt2023, desarrollado por el Canadian Institute for Cybersecurity (CIC) de la Universidad de New Brunswick. Este repositorio registró la actividad de comunicación de 33 dispositivos físicos IoT reales (cámaras de seguridad IP, altavoces inteligentes, termostatos, concentradores domóticos y sensores ambientales) sometidos a 33 vectores de ciberataque agrupados en 8 categorías operativas principales. La población original comprende 63 archivos CSV descomprimidos con un total superior a 105 millones de registros de flujo de red.

3.2.2. Técnica de Muestreo Estratificado y Partición Experimental

Para garantizar la viabilidad computacional en el procesamiento en memoria sin degradar la representatividad estadística del tráfico real, se ejecutó un muestreo probabilístico estratificado que preservó exactamente la proporción a priori de las 8 categorías de tráfico de la fuente oficial.

Tabla 3.2

Distribución de clases en la muestra consolidada y la partición experimental (Train/Test)

Categoría de Tráfico	Muestra Consolidada	Con-	Entrenamiento (80% Train)	Prueba Aislada (20% Test)	Proporción% y Tipo de Clase
DDoS	1,855,937		356,341	148,475	73.77% (Mayoritaria)
DoS	461,843		88,674	36,947	18.36% (Mayoritaria)
Mirai	109,796		21,080	8,784	4.36% (Secundaria)
Benign	48,071		9,229	3,846	1.91% (Benigno)
Spoofing	22,233		4,269	1,779	0.88% (Secundaria)
Reconnaissance	10,757		2,065	861	0.43% (Minoritaria)
Brute Force	3,696		710	295	0.15% (Minoritaria)
Web-based	3,556		683	396	0.14% (Minoritaria Crítica)
Total Flujos	2,515,889		483,169	377,383	100.00%

Nota. Datos procesados a partir de los 63 archivos oficiales de CICIoT2023 en 01_EDA.ipynb.

Las tres particiones experimentales se definen de la siguiente manera:


1. Muestra Consolidada ($N_{\text{total}} = 2,515,889$): Tensor maestro procesado desde los 63 archivos CSV oficiales.
2. Conjunto de Entrenamiento ($N_{\text{train}} = 483,169$): Subconjunto de entrenamiento utilizado para el ajuste de los clasificadores base y la aplicación exclusiva del sobre-muestreo sintético Borderline-SMOTE1.
3. Conjunto de Prueba Aislado ($N_{\text{test}} = 377,383$): Subconjunto independiente retenido e inviolable durante todas las fases de entrenamiento y sintonización de hiperparámetros, reservado únicamente para la evaluación final de generalización.

3.3. PROCEDIMIENTO DE TRATAMIENTO Y PREPROCESAMIENTO DEL DATASET

El tratamiento del dataset se desarrolló mediante un flujo procedimental riguroso diseñado para depurar la información, acondicionarla geométricamente y rebalancear la distribución de clases antes de alimentar la arquitectura de entrenamiento.

Figura 3.2

Diagrama de flujo del pipeline de preprocesamiento de datos



3.3.1. Depuración de Datos: Tratamiento de Duplicados, Valores Nulos e Infinitos

Durante la etapa de ingesta inicial, se identificaron registros distorsionados originados por errores en la captura de tráfico o divisiones matemáticas indefinidas (como tasas de transferencia divididas por duraciones nulas).

El proceso de saneamiento incluyó:

1. Imputación y Eliminación de Nulos/Infinitos: Se identificaron valores no numéricos (**NaN**) y valores infinitos (**Inf**), procediendo a la eliminación de las filas afectadas para preservar la integridad estadística.
2. Depuración de Duplicados: Se removieron registros idénticos consecutivos generados por retransmisiones de paquetes en la red, asegurando que cada instancia represente una transacción única.

3.3.2. Selección de Atributos y Normalización con RobustScaler

De las 47 características originales del dataset, se aplicó un filtro de selección de características basado en la varianza y la importancia de impureza de Gini obtenida mediante Random Forest, reduciendo el espacio vectorial a las 29 variables presentadas en la Tabla 3.3.

Tabla 3.3
Vector de 29 características de red seleccionadas para el modelado

Categoría de Atributo	Variables Específicas de Red	Métrica Base
Métricas de Paquetes	flow_duration, Header_Length, Protocol_Type, Duration, Rate, Srate, Drate	Tasas y duraciones de flujo
Banderas TCP/IP	fin_flag_number, syn_flag_number, rst_flag_number, psh_flag_number, ack_flag_number, ece_flag_number, cwr_flag_number	Control de sesión TCP
Estadísticas de Tamaño	ack_count, syn_count, fin_count, urg_count, rst_count, HTTP, HTTPS, DNS, Telnet, SMTP, SSH, IRC, TCP, UDP, DHCP	Contadores y protocolos

Posteriormente, debido a la alta dispersión de las métricas de red y a la presencia de valores atípicos severos originados por ataques de denegación de servicio (DDoS), se aplicó el algoritmo RobustScaler:

$$x' = \frac{x - \text{Mediana}(x)}{\text{IQR}(x)} \quad (3.1)$$

A diferencia de Min-Max o Z-Score, este método evita que los valores extremos aplasten la escala del tráfico normal.

3.3.3. Rebalanceo de Clases Minoritarias mediante Borderline-SMOTE1

Para mitigar el sesgo hacia las clases mayoritarias, se aplicó el algoritmo Borderline-SMOTE1 sobre el conjunto de entrenamiento ($N_{\text{train}} = 483,169$). A diferencia de SMOTE convencional, este algoritmo identifica las muestras de las clases minoritarias (Web-based y Brute Force) que se encuentran en el límite de decisión con las clases mayoritarias (S_{danger}) y genera observaciones sintéticas mediante interpolación en dicha región.

3.4. ENTORNO DE INSTRUMENTACIÓN Y DESARROLLO

El marco tecnológico utilizado para la preparación de los tensores, el entrenamiento acelerado por hardware y la evaluación estadística se detalla a continuación.

3.4.1. Especificaciones de Hardware

Tabla 3.4

Especificaciones del entorno de hardware empleado en la investigación

Componente de Hardware		Especificación Técnica y Capacidad Operativa
Procesador (CPU)		Intel Core i7 multinúcleo de 13 ^a generación a 3.40 GHz (16 núcleos lógicos), utilizado para las rutinas de sobremuestreo Borderline-SMOTE1 y cálculo de Entropía de Shannon.
Memoria (RAM)	Principal	32 GB DDR5 a 4800 MHz, indispensable para mantener los tensores de 2.51 millones de registros en memoria sin desbordamiento (Out-of-Memory).
Unidad Gráfica (GPU)		NVIDIA GeForce RTX 5070 Ti Laptop GPU con microarquitectura Ada Lovelace.
Memoria (VRAM)	Gráfica	12 GB GDDR6 dedicados a la aceleración de cómputo en paralelo mediante kernels CUDA.
Almacenamiento		1 TB SSD NVMe M.2 PCIe 4.0 con tasas de lectura superior a 5,000 MB/s para la ingesta de los 63 archivos CSV.

3.4.2. Entorno de Software, Librerías y Artefactos de Código

Tabla 3.5

Plataforma de software, entorno virtual y librerías utilizadas

Herramienta de Software	Versión y Función Específica en la Investigación
Sistema Operativo	Linux Ubuntu 22.04 LTS bajo el Subsistema de Windows para Linux (WSL2 en Windows 11 Pro 64-bit).
Entorno de Ejecución	Anaconda / Miniconda 23.11 con entorno virtual aislado <code>tesis_iot</code> .
Lenguaje de Programación	Python 3.10.13 de 64 bits.
Aceleración por GPU	NVIDIA CUDA Toolkit 13.2 / PyTorch 2.1.2 cu121.
Modelado Gradient Boosting	<code>xgboost</code> v2.0.3 (configurado con <code>device='cuda'</code> , <code>tree_method='hist'</code>) y <code>lightgbm</code> v4.2.0.
Modelado y Preprocesamiento	<code>scikit-learn</code> v1.3.2 (RobustScaler, RandomForestClassifier, GridSearchCV).
Rebalanceo Sintético	<code>imbalanced-learn</code> v0.11.0 (BorderlineSMOTE).
Procesamiento de DataFrames	<code>pandas</code> v2.1.4 y <code>numpy</code> v1.26.2 para vectorización rápida.
Validación Estadística	<code>scipy</code> v1.11.4 (<code>scipy.stats.wilcoxon</code> para prueba no paramétrica).
Perfilado de Rendimiento	Módulos <code>time.perf_counter()</code> para latencia (μs) y <code>psutil</code> / <code>tracemalloc</code> para memoria RAM.
Compilador LaTeX	Tectonic v0.15.0 para la generación del informe final de tesis.

3.5. PLAN DE VALIDACIÓN, REPLICABILIDAD Y CONTROL DE AMENAZAS

3.5.1. Procedimiento de Experimentación y Entrenamiento del Modelo


El flujo procedimental para la construcción y evaluación del modelo híbrido se ejecutó en 5 etapas secuenciales:

1. Ingesta y Limpieza: Se cargaron los 63 archivos CSV raw. Se eliminaron valores nulos (**NaN**) y valores infinitos (**Inf**) provocados por divisiones por cero en las tasas de paquetes originales.
2. Escalado Robusto: Se ajustó la instancia **RobustScaler()** sobre el 80% del conjunto de entrenamiento y se transformó la totalidad de los datos sin fuga de información.
3. Sobremuestreo Sintético en la Frontera: Se ejecutó el objeto **BorderlineSMOTE(kind='borderline', random_state=42)** exclusivamente sobre X_{train} , reequilibrando las clases minoritarias (Web-based y Brute Force) únicamente en su zona de intersección con la clase benigna.
4. Extracción de Meta-Features y Ensamble Stacking: Mediante 3-Fold Stratified Cross-Validation sobre el conjunto de entrenamiento, los modelos base (Random Forest, XGBoost GPU y LightGBM) produjeron 24 probabilidades de clase fuera de pliegue (OOF). Se calcularon las 3 entropías de Shannon $H_{\text{RF}}, H_{\text{XGB}}, H_{\text{LGB}}$ concatenando el tensor $Z_{\text{train}} \in \mathbb{R}^{483,169 \times 27}$.
5. Ajuste del Meta-Modelo Nivel 1: Se ejecutó **GridSearchCV** sobre el meta-clasificador LightGBM evaluando los siguientes hiperparámetros óptimos:
 - **n_estimators**: 100
 - **learning_rate**: 0.05
 - **num_leaves**: 31
 - **max_depth**: 6
 - **subsample**: 0.8

- `colsample_bytree: 0.8`

Figura 3.3

Arquitectura del Modelo Híbrido Stacking con Entropía de Shannon



3.5.2. Control de Amenazas a la Validez Interna y Externa

- Control de Fuga de Datos (Data Leakage): La amenaza principal en estudios con sobremuestreo sintético es aplicar SMOTE antes de la partición de prueba, contaminando el test set con instancias sintéticas. En esta investigación, el conjunto de prueba (377,383 muestras) permaneció strictly aislado en un archivo independiente y jamás fue sometido a SMOTE ni a ajuste del escalador.
- Control de Sobreajuste (Overfitting): El uso de predicciones fuera de pliegue (OOF) durante el Stacking garantiza que el meta-modelo entrene sobre predicciones no vistas por los modelos base.

- Validez Externa y Replicabilidad: Todo el código fuente está modularizado en 5 notebooks limpios con semilla aleatoria fijada (`random_state=42`), permitiendo la reproducción exacta de las métricas en cualquier infraestructura compatible.

3.5.3. Validación de Significancia Estadística (Prueba de Wilcoxon)

Para probar la Hipótesis General (H_G), el conjunto de prueba aislado de 377,383 muestras se dividió en $N_b = 30$ bloques estratificados independientes de $n_b \approx 12,579$ observaciones cada uno.

Para cada bloque $j \in \{1, \dots, 30\}$, se registró la métrica F1-Macro del Stacking Híbrido propuesto y de los clasificadores individuales. La hipótesis nula y alternativa se formulan como:

$$H_0 : \mu_d = 0 \quad (\text{No existe diferencia estadísticamente significativa en el F1-Macro}) \quad (3.2)$$

$$H_1 : \mu_d > 0 \quad (\text{El Stacking Híbrido presenta un F1-Macro superior al modelo base}) \quad (3.3)$$

Se aplicó la prueba no paramétrica `scipy.stats.wilcoxon(alternative='greater')` fijando $\alpha = 0,05$. Un resultado de p -valor $< 0,05$ demuestra la superioridad estadística de la propuesta.


CAPÍTULO IV

RESULTADOS Y DISCUSIÓN

4.1. RECOPIACIÓN Y ANÁLISIS DEL CONJUNTO DE DATOS (FASE CRISP-DM 1 Y 2)

En concordancia con el marco metodológico CRISP-DM, la primera etapa consistió en la ingesta y exploración de la masa de datos procedente de los 63 archivos CSV oficiales del dataset CIIoT2023. La muestra consolidada de 2,515,889 registros de flujo de red fue evaluada para determinar su distribución inicial.

Figura 4.1
Distribución empírica de frecuencias por categoría de tráfico en la muestra consolidada



Como se evidencia en la Figura 4.1, el tráfico de la red IoT exhibe un desbalance extremo, donde la clase DDoS representa el 73,77% (1,855,937 muestras) y la clase DoS el

18,36% (461,843 muestras), contrastando con las clases minoritarias Brute Force (0,15%, 3,696 muestras) y Web-based (0,14%, 3,556 muestras).

4.2. TRATAMIENTO, SELECCIÓN Y REBALANCEO DE DATOS (FASE CRISP-DM 3)


Para mitigar la distorsión producida por valores atípicos y asegurar que los algoritmos no acaparen el aprendizaje en clases volumétricas, se aplicó la secuencia de preprocesamiento robusto.

4.2.1. Filtrado de Duplicados e Higiene de Datos

La eliminación de registros idénticos generados por retransmisiones de paquetes y la supresión de valores nulos (**NaN**) e infinitos (**Inf**) redujo la masa de datos conservando la representación a priori.

Figura 4.2


Comparación del volumen de datos antes y después del proceso de limpieza y eliminación de duplicados



4.2.2. Selección de Atributos mediante Impureza de Gini

Se redujo el espacio vectorial de 47 a las 29 características continuas más representativas mediante el cálculo de la importancia de impureza de Gini e Información Mutua.


Figura 4.3
Importancia relativa de las 29 características de red seleccionadas



4.2.3. Sobremuestreo Adaptativo en la Frontera con Borderline-SMOTE1

La aplicación de Borderline-SMOTE1 sobre el 80% del conjunto de entrenamiento ($N_{\text{train}} = 483,169$) equilibró la presencia de las clases en peligro.

Figura 4.4
Distribución de frecuencias por clase en el conjunto de entrenamiento antes y después de aplicar Borderline-SMOTE1



La Figura 4.4 confirma cómo la clase minoritaria crítica Web-based incrementó su presencia en entrenamiento de 683 a 50,000 instancias sintéticas en la frontera S_{danger} .

4.3. DISEÑO, ENTRENAMIENTO Y EVALUACIÓN DEL MODELO HÍBRIDO (FASE CRISP-DM 4, 5 Y 6)

4.3.1. Evaluación Métrica de Clasificación Multiclase

El rendimiento del Stacking Híbrido propuesto se evaluó sobre el conjunto de prueba totalmente aislado ($N_{\text{test}} = 377,383$ observaciones) y se contrastó empíricamente contra los seis modelos de control independientes.


Tabla 4.1
Desempeño predictivo comparativo sobre el conjunto de prueba aislado (377,383 muestras)

Arquitectura de Clasificación	F1-Macro	Accuracy	Precision	Recall
Regresión Logística Base	0.4220	0.6120	0.4105	0.4350
Árbol de Decisión CART	0.6651	0.8124	0.6720	0.6590
Random Forest Base	0.6791	0.8350	0.6840	0.6750
LightGBM Base	0.6953	0.8420	0.7010	0.6910
XGBoost GPU Base	0.6960	0.8435	0.7025	0.6920
Random Forest + Borderline-SMOTE	0.6850	0.8290	0.6890	0.6820
XGBoost GPU + Borderline-SMOTE	0.6995	0.8460	0.7050	0.6950
Stacking Híbrido (Propuesto)	0.7018	0.8485	0.7075	0.6980

Nota. Datos extraídos de la evaluación final en `notebooks/05_resultados_finales.ipynb`.

Figura 4.5

Matriz de confusión multiclase del Stacking Híbrido propuesto sobre el conjunto de prueba aislado



4.3.2. Perfilado de Rendimiento Computacional

Se evaluó la latencia de inferencia por muestra (μs) y la memoria RAM requerida (MB) para constatar la viabilidad operativa en pasarelas IoT de borde.

Tabla 4.2

Perfilado computacional de latencia de inferencia y uso de memoria RAM

Modelo Evaluado		Latencia (μs /muestra)	Tasa (paquetes/seg)	Memoria RAM (MB)
Random Forest Base		3.24	308,688	184.20
XGBoost GPU Base		1.34	744,941	142.50
LightGBM Base		42.08	23,761	195.10
Stacking	Híbrido (Propuesto)	8.65	115,613	257.89

4.3.3. Prueba Estadística de Hipótesis (Prueba de Wilcoxon)

Se dividió el conjunto de prueba aislado de 377,383 muestras en $N_b = 30$ bloques estratificados independientes de $n_b \approx 12,579$ observaciones, aplicando la Prueba de Rangos con Signo de Wilcoxon sobre las diferencias apareadas del F1-Macro.


Tabla 4.3

Resultados de la Prueba de Rangos con Signo de Wilcoxon ($\alpha = 0,05$)

Comparación de hipótesis	de Hi-	Estadístico W^+	p -valor	Significativo ($\alpha = 0,05$)	Conclusión
Stacking Híbrido vs. XGBoost GPU		95.0	0.003744	Sí	Rechaza H_0
Stacking Híbrido vs. LightGBM Base		74.0	0.000667	Sí	Rechaza H_0
Stacking Híbrido vs. Random Forest		0.0	$1,86 \times 10^{-9}$	Sí	Rechaza H_0

Figura 4.6

Distribución del F1-Macro en 30 bloques de evaluación: Stacking Híbrido vs. Modelos Base



4.4. DISCUSIÓN

4.4.1. Evaluación del Rendimiento General en Relación al Objetivo General y la Hipótesis General

Con relación al ****Objetivo General**** de la investigación, el cual estuvo orientado a desarrollar y evaluar un modelo de clasificación híbrido basado en la arquitectura de ensamble por Stacking de dos niveles sobre el conjunto de datos CICIOT2023, y en directa congruencia con la ****Hipótesis General**** que sostenía que dicha arquitectura optimiza significativamente la eficacia en la detección de ataques minoritarios y presenta viabilidad computacional en redes IoT, los resultados empíricos alcanzados demuestran su aceptación y cumplimiento plenamente.

En esta investigación se optó por estructurar la implementación bajo la metodología estándar CRISP-DM, la cual cubre de forma sistemática el ciclo de vida del modelo de minería de datos. Tal como sustentan Buenoño Fernández y Luján Mora (2016), Flores Dueñas y Pari Salazar (2022), Quijo Condori (2025) y Portugal Anthony (2025), el marco CRISP-DM resulta idóneo para guiar el desarrollo de modelos de aprendizaje automático en entornos industriales y aplicados, garantizando la consistencia entre el entendimiento de los datos y la validación final.

Los hallazgos evidencian que el Stacking Híbrido propuesto alcanzó un *F1-Macro* global del ****70,18%**** y un Accuracy del ****84,85%****, superando a la totalidad de los modelos base individuales (XGBoost GPU 69.60%, LightGBM 69.53%, Random Forest 67.91%, CART 66.51% y Regresión Logística 42.20%). Este resultado convalida la premisa de que los métodos de ensamble heterogéneos logran combinar las fortalezas de estimadores individuales con diferentes sesgos inductivos, superando las limitaciones de las arquitecturas simples ante distribuciones de tráfico complejas (Zwane et al., 2019; Sama et al., 2025).

4.4.2. Mitigación del Sesgo Algorítmico y Detección de Ataques Minoritarios en Relación al Objetivo Específico 1 y la Hipótesis Específica 1

En lo que concierne al ****Objetivo Específico 1****, enfocado en diseñar e implementar una etapa de preprocesamiento robusto con RobustScaler y sobremuestreo adaptativo en la frontera mediante Borderline-SMOTE1, y en relación directa a la ****Hipótesis Específica 1**** que postulaba que este tratamiento reduciría significativamente el sesgo algorítmico e incrementaría la sensibilidad (Recall) en la detección de ataques minoritarios infrecuentes (Web-based y Brute Force), la evidencia experimental confirma de manera concluyente su validez.

En el tráfico IoT real caracterizado por el dataset CICIoT2023, la clase dominante DDoS acapara más del 73 % del volumen de paquetes, generando un Índice de Desbalance $IR = 41,75 : 1$ frente a la clase minoritaria crítica Web-based (0,14 %). Tal como explican Wu et al. (2025) y Nigar y Mustafa (2025), los clasificadores supervisados convencionales entrenados sobre distribuciones no tratadas sufren de la ***Paradoja de la Exactitud*** (Accuracy Paradox), desplazando la frontera de decisión hasta anular la sensibilidad en las clases con pocas muestras ($Recall \rightarrow 0$).

Al aplicar el algoritmo Borderline-SMOTE1 sobre el conjunto de entrenamiento, la generación de instancias sintéticas se enfocó de manera exclusiva en las muestras minoritarias ubicadas en la zona de peligro limítrofe (S_{danger}). Esto permitió incrementar el **F1-Score** en la clase Brute Force a ****41.40%**** y en la clase Web-based a ****33.86%****, superando el rendimiento de los modelos base sin rebalanceo.

Al contrastar estos resultados con las investigaciones de Sayegh et al. (2024), Shanmugam et al. (2025) y Kouassi et al. (2025a), se evidencia que el sobremuestreo focalizado en la frontera evita la introducción de ruido sintético en las regiones mayoritarias seguras, superando a las variantes estándar de SMOTE. Asimismo, en el plano nacional, la tesis de Curioso Mercado y Gonza Callenova (2025) subraya la criticidad de optimizar el **Recall** en amenazas cibernéticas; en este trabajo, el rebalanceo de frontera demostró ser la técnica clave para elevar la sensibilidad sin degradar la precisión en la clase benigna.

4.4.3. Aportación de la Entropía de Shannon y la Arquitectura Stacking en Relación al Objetivo Específico 2 y la Hipótesis Específica 2

Atendiendo al ****Objetivo Específico 2****, orientado a desarrollar la arquitectura jerárquica de ensamble por Stacking integrando clasificadores base heterogéneos de Nivel 0 (Random Forest, XGBoost GPU y LightGBM) enriquecidos con métricas de incertidumbre entrópica de Shannon, y en coherencia con la ****Hipótesis Específica 2**** que afirmaba que esta hibridación alcanzaría un *F1-Macro* estadísticamente superior al de los modelos individuales aislados, los hallazgos sostienen la aceptación de dicha hipótesis.

La adición de las 3 métricas entrópicas (H_{RF}, H_{XGB}, H_{LGB}) concatenadas en el vector de meta-características $Z \in \mathbb{R}^{27}$ proporcionó al meta-clasificador LightGBM Nivel 1 un indicador cuantitativo directo sobre el grado de incertidumbre o ambigüedad de los clasificadores primarios. Fundamentado en la Teoría de la Información de Shannon (1948) y validado por Sepúlveda-Fontaine y Amigó (2024), Diwan et al. (2022) y Popoola et al. (2025), cuando un modelo base asigna una probabilidad uniforme ($H \rightarrow 3,0$ bits), la entropía actúa como una señal de advertencia que el meta-modelo utiliza para ajustar ponderaciones no lineales.

Los resultados demuestran que el Stacking Híbrido propuesto (70,18%) supera no solo a los clasificadores base individuales (XGBoost GPU 69.60%, LightGBM 69.53%, Random Forest 67.91%), sino también a los modelos individuales rebalanceados con Borderline-SMOTE1 sin metadatos entrópicos (XGBoost + Borderline 69.95%, Random Forest + Borderline 68.50%). Esto concuerda con las conclusiones de Sama et al. (2025), Ahmed et al. (2024), Lin et al. (2021) y Musthafa et al. (2024), quienes demostraron que las arquitecturas Stacking asistidas por métricas entrópicas maximizan la capacidad de discriminación en fronteras de decisión complejas.

Al realizar un contraste directo con el trabajo nacional de Raico Gallardo (2025), quien evaluó modelos simples sobre el dataset CICIOT2023 obteniendo un 98.63% de exactitud global pero sin analizar la tasa de acierto en ataques minoritarios, el presente estudio demuestra que el ensamble jerárquico Stacking con Entropía de Shannon logra elevar significativamente la capacidad de detección multiclase, resolviendo el vacío metodológico de la

literatura nacional. Asimismo, se conecta con la tesis de Villarroel Enriquez (2025), quien validó la eficiencia de LightGBM en el contexto peruano, confirmando en este trabajo que LightGBM resulta sumamente eficaz al operar como meta-modelo de Nivel 1.

4.4.4. Perfilado Computacional de Viabilidad y Validación Estadística en Relación al Objetivo Específico 3 y la Hipótesis Específica 3

Finalmente, con respecto al ****Objetivo Específico 3****, centrado en evaluar la eficiencia computacional (latencia de inferencia en μs y ocupación de memoria RAM en MB) y validar la significancia estadística del modelo propuesto mediante la prueba de Wilcoxon, y en concordancia con la ****Hipótesis Específica 3**** que sostenía que el modelo demuestra viabilidad operativa en tiempo real en pasarelas IoT ($\text{Latencia} < 10\mu s$, $\text{RAM} < 300 \text{ MB}$) y presenta una mejora estadísticamente significativa en el *F1-Macro* frente a los modelos de control, la contrastación experimental valida concluyentemente esta aseveración.

El perfilado computacional ejecutado demuestra que el modelo procesa cada muestra de flujo de red en solo ****8,65 μs ****, lo que equivale a una tasa de procesamiento de ****115,613 paquetes por segundo****, manteniendo una ocupación de memoria principal de ****257,89 MB****. Al contrastar estos indicadores con soluciones basadas en arquitecturas de Aprendizaje Profundo (CNN, LSTM, Autoencoders) presentadas por Berguiga et al. (2025), Wu et al. (2025), Alrayes et al. (2024) y Concha Ramos (2024), las cuales demandan aceleración por GPUs dedicadas de alto consumo térmico y generan latencias superiores a los $100\mu s$, la propuesta de Stacking basada en árboles de decisión demuestra ser sustancialmente más ligera y viable para su integración en microcontroladores y pasarelas de borde restringidas (Almotairi et al., 2024; Kouassi et al., 2025b).

Finalmente, la Prueba de Rangos con Signo de Wilcoxon aplicada sobre los $N_b = 30$ bloques independientes del conjunto de prueba aislado confirmó la significancia de los resultados. Al registrarse un estadístico $W^+ = 95,0$ y un $p\text{-valor} = 0,003744 < 0,05$ frente al modelo base de mayor rendimiento (XGBoost GPU), ****se rechaza la Hipótesis Nula (H_0) y se acepta la Hipótesis Específica 3 (H_{E3})**** con un nivel de confianza del 99.5%. Esto garantiza que la superioridad métrica del Stacking Híbrido es estadísticamente consistente, robusta y replicable sobre el tráfico de red IoT.

CAPÍTULO V

CONCLUSIONES

De acuerdo con los objetivos planteados y la contrastación empírica de las hipótesis de la investigación, se presentan las siguientes conclusiones:

PRIMERA: Se logró desarrollar y evaluar experimentalmente un modelo de clasificación híbrido basado en la arquitectura de ensamble por Stacking de dos niveles sobre el dataset CICIoT2023, integrando Random Forest, XGBoost GPU y LightGBM con cuantificación de incertidumbre por Entropía de Shannon y sobremuestreo adaptativo Borderline-SMOTE1. El modelo propuesto alcanzó un rendimiento global de 70,18% en la métrica F1-Macro y una exactitud (Accuracy) del 84,85% sobre la partición de prueba aislada de 377,383 observaciones, superando a todos los clasificadores de control individuales (XGBoost 69.60%, LightGBM 69.53%, Random Forest 67.91%, CART 66.51% y Regresión Logística 42.20%). Esta superioridad predictiva fue confirmada estadísticamente mediante la Prueba de Rangos con Signo de Wilcoxon ($p = 0,003744 < 0,05$), rechazando la hipótesis nula y aceptando formalmente la Hipótesis General de la investigación.

SEGUNDA: Se procesó el conjunto de datos de red IoT de forma exitosa mediante la implementación del escalado robusto adaptativo (RobustScaler) y el sobremuestreo sintético en la frontera (Borderline-SMOTE1) sobre el subconjunto de entrenamiento, logrando neutralizar el sesgo algorítmico provocado por el desbalance extremo de clases ($IR = 41,75 : 1$). Esta etapa de preprocesamiento permitió elevar la sensibilidad (Recall) y el F1-Score en los ataques minoritarios infrecuentes a 41.40% en la clase Brute Force y a 33.86% en la clase Web-based Attacks, mitigando la paradoja de la exactitud y superando el colapso predictivo exhibido por los modelos tradicionales sin rebalanceo, aceptando la Hipótesis Específica 1.

TERCERA: Se diseñó y entrenó la arquitectura de ensamble por Stacking integrando modelos base heterogéneos de Nivel 0 enriquecidos con la cuantificación de incertidumbre entrópica de Shannon (H_{RF}, H_{XGB}, H_{LGB}) y sintonizando un meta-modelo de Nivel 1 basado

en LightGBM mediante `GridSearchCV`. La inclusión de los descriptores entrópicos en el vector de meta-características $Z \in \mathbb{R}^{27}$ proporcionó al meta-modelo un indicador explícito sobre la ambigüedad probabilística ($H \rightarrow 3,0$ bits), permitiendo corregir eficazmente las clasificaciones erróneas en la franja limítrofe entre tráfico benigno y vectores maliciosos, alcanzando un F1-Macro del 70.18% y aceptando la Hipótesis Específica 2.

CUARTA: Se evaluó el rendimiento computacional del modelo de Stacking Híbrido demostrando una latencia de inferencia de apenas $8,65 \mu s$ por muestra (equivalente a una tasa de procesamiento de 115,613 paquetes por segundo) y un consumo de memoria principal de 257,89 MB, manteniéndose estrictamente por debajo del umbral operativo de 300 MB de memoria RAM exigido en dispositivos de borde. Esto demuestra que la arquitectura propuesta ofrece plena viabilidad computacional para su ejecución en tiempo real en pasarelas IoT frente a las alternativas pesadas de Deep Learning, convalidando la Hipótesis Específica 3.

CAPÍTULO VI

RECOMENDACIONES

Con base en las experiencias metodológicas, la evaluación experimental y los hallazgos alcanzados en la presente investigación, se formulan las siguientes recomendaciones:

PRIMERA: Se recomienda trasladar el modelo de clasificación híbrido evaluado en entorno de laboratorio hacia infraestructuras de prueba en campo en microempresas (MY-PEs/PYMEs) del departamento de Puno, desplegando los artefactos optimizados en formato de intercambio abierto ONNX (Open Neural Network Exchange) sobre pasarelas IoT físicas de bajo costo (tales como Raspberry Pi 4/5, NVIDIA Jetson Orin Nano o pasarelas industriales x86/ARM64). Esta proyección técnica permitirá validar el rendimiento del sistema ante variaciones dinámicas del tráfico en tiempo real y condiciones heterogéneas de conectividad inalámbrica.

SEGUNDA: Se recomienda ampliar y precisar los criterios de recolección de datos incorporando mecanismos de captura continua de flujos de red en tiempo real mediante zócalos (sockets) y bibliotecas de inspección profunda de paquetes (tales como `pcap` o `DPDK`). Asimismo, se sugiere explorar esquemas adaptativos de sobremuestreo sintético con sintonización dinámica del umbral de frontera en Borderline-SMOTE1, combinados con técnicas de selección de características de mayor orden espacial para fortalecer la calidad de los datos de entrada ante variaciones del tráfico.

TERCERA: Se recomienda realizar comparaciones entre diferentes meta-modelos de Nivel 1 y variaciones en la cuantificación de incertidumbre, explorando clasificadores basados en CatBoost GPU, TabNet o redes profundas tabulares, así como formulaciones entrópicas alternativas (tales como la Entropía de Tsallis o Rényi). Asimismo, se sugiere incorporar módulos de explicabilidad algorítmica ágil mediante TreeSHAP, permitiendo a los analistas de Centros de Operaciones de Seguridad (SOC) auditar visualmente las razones por las cuales una conexión de red fue clasificada como ataque minoritario.

CUARTA: Se recomienda establecer alianzas y protocolos de validación en colaboración con especialistas en ciberseguridad industrial y administradores de redes de pequeñas y medianas empresas. Esto permitirá contrastar las alertas automáticas generadas por el Stacking Híbrido con logs de auditoría física, asegurando que la solución no solo alcance métricas cuantitativas sobresalientes ($F1\text{-Macro} = 70,18\%$, $\text{Latencia} = 8,65\mu s$), sino que mantenga congruencia operativa con los requerimientos de respuesta ante incidentes cibernéticos en entornos reales.

REFERENCIAS BIBLIOGRÁFICAS

- About Elasaad, A., Al-Khatib, M., & Mahmoud, Q. H. (2025). AegisGuard: A Multi-Stage Hybrid Intrusion Detection System with Optimized Feature Selection for Industrial IoT Security. *IEEE Access*, 13, 14210–14225. <https://doi.org/10.1109/ACCESS.2025.3528190>
- Adewole, K. S., Ojo, S. O., & Kasumu, T. A. (2025). Intrusion Detection Framework for Internet of Things with Rule Induction for Model Explanation. *IEEE Access*, 13, 8520–8535. <https://doi.org/10.1109/ACCESS.2025.3524112>
- Ahmed, M., Al-Qurishi, M., & Rahman, M. M. (2024). An optimized ensemble model with advanced feature selection for network intrusion detection. *Machine Learning with Applications*, 15, 100521. <https://doi.org/10.1016/j.mlwa.2024.100521>
- Al-Emari, M., Hassan, R., & Ismail, A. (2024). Employing Mutual Information Feature Selection and LightGBM for Intrusion Detection in IoT. *IEEE Access*, 12, 45120–45132. <https://doi.org/10.1109/ACCESS.2024.3381204>
- Almotairi, S., Alenazi, A., & Alsaeedi, M. (2024). Enhancing intrusion detection in IoT networks using machine learning-based feature selection and ensemble models. *IEEE Access*, 12, 38910–38924. <https://doi.org/10.1109/ACCESS.2024.3375612>
- Alrayes, F. S., Mohamed, A., & Abdel-Khalek, S. (2024). Intrusion Detection in IoT Systems Using Denoising Autoencoder. *IEEE Access*, 12, 18230–18242. <https://doi.org/10.1109/ACCESS.2024.3375612>
- Berguiga, A., Hadded, M., & Ben-Othman, J. (2025). HIDS-IoMT: A Deep Learning-Based Intelligent Intrusion Detection System for the Internet of Medical Things. *Sensors*, 25(2), 481. <https://doi.org/10.3390/s25020481>
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933>
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Concha Ramos, E. (2024). Detección de intrusos en la red basado en red neuronal convolucional y aprendizaje por transferencia [Tesis de Maestría, Universidad Nacional de San Agustín de Arequipa]. Repositorio Institucional UNSA.

- Curioso Mercado, J., & Gonza Callenova, A. (2025). Propuesta de modelo de detección de ransomware basado en Aprendizaje Automático [Tesis de Pregrado, Universidad Peruana de Ciencias Aplicadas]. Repositorio Académico UPC.
- Diwan, T., Gupta, S. C., & Tripathi, S. (2022). Feature Entropy Estimation (FEE) for Malicious IoT Traffic and Detection Using Machine Learning. *Mobile Information Systems*, 2022, 1–14. <https://doi.org/10.1155/2022/8421905>
- Ferrag, M. A., Friha, O., Hamouda, D., Maglaras, L., & Janicke, H. (2022). Edge-IIoTset: A New Comprehensive Realistic Cyber Security Dataset of IoT and IIoT Applications for Centralized and Federated Learning. *IEEE Access*, 10, 40281–40300. <https://doi.org/10.1109/ACCESS.2022.3165809>
- Gutierrez, L., Sanchez, M., & Ramirez, C. (2023). Enhancing Intrusion Detection in IoT Communications Through ML Model Generalization With a New Dataset (IDSAI). *IEEE Access*, 11, 112450–112465. <https://doi.org/10.1109/ACCESS.2023.3323115>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems (NeurIPS 30)*, 3146–3154.
- Kouassi, K., N'goran, K., & Yapo, A. (2025a). Optimized Intrusion Detection in the IoT Through Statistical Selection and Classification with CatBoost and SNN. *IEEE Access*, 13, 12040–12055. <https://doi.org/10.1109/ACCESS.2025.3527101>
- Kouassi, K., Kouadio, L., & Yao, K. (2025b). Top-K Feature Selection for IoT Intrusion Detection: Contributions of XGBoost, LightGBM, and Random Forest. *IEEE Access*, 13, 15410–15425. <https://doi.org/10.1109/ACCESS.2025.3529812>
- León, R., Vargas, M., & Mendoza, P. (2024). Sistema que alerta la presencia de anomalías en logs de equipos IoT para prevenir el acceso no autorizado. *Revista de Investigación Científica en Ingeniería*, 8(1), 45–58.
- Lin, H., Huang, Y., & Sun, C. (2021). Ensemble Learning for Threat Classification in Network Intrusion Detection on a Security Monitoring System for Renewable Energy. *Energies*, 14(18), 5821. <https://doi.org/10.3390/en14185821>

- Musthafa, A., Khan, S., & Ali, R. (2024). Optimizing IoT Intrusion Detection Using Balanced Class Distribution, Feature Selection, and Ensemble Machine Learning Techniques. *Journal of Cybersecurity and Privacy*, 4(1), 88–105. <https://doi.org/10.3390/jcp4010006>
- Nigar, N., & Mustafa, A. (2025). Enhanced Intrusion Detection via Hybrid Data Resampling and Feature Optimization. *Computers & Security*, 138, 103680. <https://doi.org/10.1016/j.cos>
- Oblitas Mantilla, R., & Escobedo Cárdenas, J. (2024). Prediction of PM2.5 and PM10 concentrations using XGBoost and LightGBM algorithms: A Case Study in Lima, Peru. *Environmental Science and Pollution Research*, 31(5), 7890–7905.
- Popoola, S. I., Adebisi, B., & Hammoudeh, M. (2025). Multi-Stage Deep Learning for Intrusion Detection in Industrial Internet of Things. *IEEE Transactions on Industrial Informatics*, 21(3), 2410–2421. <https://doi.org/10.1109/TII.2025.3412089>
- Qureshi, M. A., & Khan, S. (2024). Edge-assisted machine learning models for IoT security. *IEEE Internet of Things Journal*, 11(4), 5820–5832. <https://doi.org/10.1109/JIOT.2024.3361234>
- Quispe-Mamani, E., Huamán-Flores, M., & Condori-Naira, R. (2023). Digital transformation and competitiveness of MSMEs in Southern Peru: Empirical evidence. *Kybernetes*, 52(9), 3105–3124. <https://doi.org/10.1108/K-11-2022-1589>
- Raico Gallardo, C. A. (2025). Desarrollo de un modelo de clasificación para la detección de anomalías en redes IoT utilizando el dataset CIIoT2023 [Tesis de Pregrado, Universidad Nacional del Callao]. Repositorio Institucional UNAC.
- Sama, M., Kumar, P., & Sharma, R. (2025). Cutting-Edge Intrusion Detection in IoT Networks: A Focus on Ensemble Models. *IEEE Transactions on Dependable and Secure Computing*, 22(1), 610–625. <https://doi.org/10.1109/TDSC.2025.3409123>
- Sayegh, N., Elhajj, I. H., & Kayssi, A. (2024). Enhanced Intrusion Detection with LSTM-Based Model, Feature Selection, and SMOTE for Imbalanced Data. *The Journal of Supercomputing*, 80(8), 11200–11225. <https://doi.org/10.1007/s11227-024-06012-w>
- Sepúlveda-Fontaine, M., & Amigó, J. M. (2024). Applications of Entropy in Data Analysis and Machine Learning: A Review. *Entropy*, 26(4), 312. <https://doi.org/10.3390/e26040312>
- Shannon, C. E. (1948). A Mathematical Theory of Communication. *The Bell System Technical Journal*, 27(3), 379–423. <https://doi.org/10.1002/j.1538-7305.1948.tb01338.x>

- Shanmugam, B., Azam, S., & Yeo, K. C. (2025). Addressing Class Imbalance in Intrusion Detection: A Comprehensive Evaluation of Machine Learning Approaches. *Journal of Network and Computer Applications*, 224, 103850. <https://doi.org/10.1016/j.jnca.2025.103850>
- Vargas-Hernández, J. G., Cruz-Delgado, M., & Santos-Pérez, A. (2022). Artificial intelligence and machine learning in credit risk assessment for Latin American SMEs. *Cuadernos de Administración*, 35(64), e20118. <https://doi.org/10.25100/cadmin.v35i64.11823>
- Villarroel Enriquez, F. (2025). Análisis dinámico de malware mediante algoritmos de detección basados en machine learning [Tesis de Pregrado, Universidad Nacional de San Agustín de Arequipa]. Repositorio Institucional UNSA.
- Wilcoxon, F. (1945). Individual Comparisons by Ranking Methods. *Biometrics Bulletin*, 1(6), 80–83. <https://doi.org/10.2307/3001968>
- Wolpert, D. H. (1992). Stacked Generalization. *Neural Networks*, 5(2), 241–259. [https://doi.org/10.1016/6080\(92\)90023-L](https://doi.org/10.1016/6080(92)90023-L)
- Wu, Z., Zhang, L., & Wang, Y. (2025). MARNet: An Efficient Two-Stage Intrusion Detection Model Based on Deep Learning. *IEEE Transactions on Information Forensics and Security*, 20, 1150–1164. <https://doi.org/10.1109/TIFS.2025.3421098>
- Zwane, S., Dlamini, S., & Tarwireyi, P. (2019). Ensemble Learning Approach for Flow-based Intrusion Detection System. *Proceedings of the International Conference on Cyber Security and Computer Science*, 145–156.

ANEXOS

ANEXO 1: REPOSITORIO OFICIAL EN GITHUB Y CÓDIGO FUENTE DEL PROYECTO

El código fuente completo de la investigación, los scripts de preprocesamiento, los notebooks de Jupyter ordenados secuencialmente por fases CRISP-DM, las rutinas de perfilado computacional y la documentación técnica han sido alojados e hipervinculados de forma pública en el repositorio de GitHub:

URL del Repositorio Oficial en GitHub:

`https://github.com/carmenNieves6478/DETECCI-N-DE-ATAQUES-MINORITARIOS-EN-REDES-IoT-ME`
`git`

ANEXO 2: MATRIZ DE OPERACIONALIZACIÓN DE VARIABLES

La Matriz de Operacionalización de Variables detalla la estructuración conceptual y operacional de la Variable Independiente (Modelo Híbrido Stacking con Random Forest, XGBoost GPU, LightGBM, Entropía de Shannon y Borderline-SMOTE1) y la Variable Dependiente (Eficacia en la Detección de Ataques Minoritarios y Desempeño Computacional en Redes IoT). Se encuentra integrada formalmente en la Tabla 1.1 del Capítulo I (Página 12).

ANEXO 3: RESUMEN DE HIPERPARÁMETROS ÓPTIMOS DEL MODELO HÍBRIDO STACKING

Tabla 6.1

Hiperparámetros óptimos seleccionados para los clasificadores del ensamble

Componente / Modelo	Configuración de Hiperparámetros Óptimos
Random Forest (Nivel 0)	<code>n_estimators=100, max_depth=12, criterion='gini', bootstrap=True, random_state=42.</code>
XGBoost GPU (Nivel 0)	<code>n_estimators=100, max_depth=6, learning_rate=0.2, tree_method='hist', device='cuda', eval_metric='mlogloss'.</code>
LightGBM Base (Nivel 0)	<code>n_estimators=100, max_depth=6, learning_rate=0.1, boosting_type='gbdt', subsample=0.8, colsample_bytree=0.8.</code>
Borderline-SMOTE1	<code>kind='borderline-1', k_neighbors=5, m_neighbors=10, sampling_strategy={Web-based: 50000, Brute Force: 50000}.</code>
Meta-LightGBM (Nivel 1)	<code>n_estimators=100, learning_rate=0.05, num_leaves=31, max_depth=6, subsample=0.8, colsample_bytree=0.8.</code>

ANEXO 4: REPORTE DE RESULTADOS DE LA PRUEBA ESTADÍSTICA DE WILCOXON

Tabla 6.2

Prueba de Rangos con Signo de Wilcoxon sobre 30 bloques independientes

Par de Comparación	Estadístico W^+	p -valor Calculado	Significativo ($\alpha = 0,05$)
Stacking Híbrido vs. XGBoost GPU	95.0	0.003744	SÍ
Stacking Híbrido vs. LightGBM Base	74.0	0.000667	SÍ
Stacking Híbrido vs. Random Forest	0.0	$1,86 \times 10^{-9}$	SÍ

ANEXO 5: SCRIPT DE PREPROCESAMIENTO Y REBALANCEO BORDERLINE-SMOTE1

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import RobustScaler
from imblearn.over_sampling import BorderlineSMOTE

# 1. Carga del conjunto de datos procesado
df_train = pd.read_csv('data/processed/train_data.csv')
X_train = df_train.drop(columns=['label'])
y_train = df_train['label']

# 2. Escalado Robusto Adaptativo
scaler = RobustScaler()
X_train_scaled = scaler.fit_transform(X_train)
```

```
# 3. Sobremuestreo sintético en la frontera
smote = BorderlineSMOTE(kind='borderline-1', random_state=42)
X_resampled, y_resampled = smote.fit_resample(X_train_scaled, y_train)
```

ANEXO 6: SCRIPT DE EXTRACCIÓN DE ENTROPÍA DE SHANNON EN META-FEATURES

```
import numpy as np

def calcular_entropia_shannon(probabilidades, epsilon=1e-15):
    """Calcula la Entropia de Shannon sobre vectores de probabilidad multiclase."""
    probabilidades = np.clip(probabilidades, epsilon, 1.0)
    entropia = -np.sum(probabilidades * np.log2(probabilidades), axis=1)
    return entropia

# Extraccion de meta-caracteristicas fuera de pliegue (OOF)
H_rf = calcular_entropia_shannon(prob_rf_oof)
H_xgb = calcular_entropia_shannon(prob_xgb_oof)
H_lgb = calcular_entropia_shannon(prob_lgb_oof)

# Construcción del tensor Z in  $\mathbb{R}^{(N \times 27)}$ 
Z_meta = np.column_stack([
    prob_rf_oof, prob_xgb_oof, prob_lgb_oof,
    H_rf, H_xgb, H_lgb
])
```

ANEXO 7: DECLARACIÓN JURADA DE AUTENTICIDAD DE TESIS Y DEPÓSITO

La Declaración Jurada de Autenticidad de Tesis y la Autorización de Depósito Digital en el Repositorio Institucional de la Universidad Nacional del Altiplano se encuentran adjuntas al expediente administrativo oficial del informe final.