

DETECCIÓN DE ATAQUES MINORITARIOS EN REDES IoT MEDIANTE UN MODELO HÍBRIDO BASADO EN STACKING, XGBOOST Y LIGHTGBM, PUNO 2026

Sustentación de Tesis para Optar el Título Profesional de Ingeniera de Sistemas

Bach. Carmen Nieves Apaza Condori

Escuela Profesional de Ingeniería de Sistemas
Facultad de Ingeniería Mecánica Eléctrica, Electrónica y Sistemas
Universidad Nacional del Altiplano - Puno

30 de Julio de 2026

El Problema Crítico: Sesgo Algorítmico y Desbalance en IoT

Desbalance Extremo en Tráfico IoT (IR = 41,75 : 1)

- El **95.53 %** del tráfico corresponde a ataques volumétricos masivos (DDoS/DoS) y botnets.
- Los **ataques minoritarios infrecuentes** (*Web-based* 0.14 % y *Brute Force* 0.15 %) son los más destructivos pero quedan invisibilizados.

La Paradoja de la Exactitud (Accuracy Paradox)

Los clasificadores tradicionales obtienen $> 84 \%$ de exactitud global simplemente por predecir la clase mayoritaria, pero sufren una **sensibilidad nula** (Recall $\rightarrow 0$) en intrusiones críticas.





Figura 1: Distribución asimétrica de clases en el dataset
CICIoT2023.


Solución Propuesta: Arquitectura Stacking Híbrida de 2 Niveles




Preprocesamiento y Selección de Atributos ($d = 29$)

Higiene de Datos y Limpieza

Comparativa de Distribuciones: Antes vs Después del Procesamiento y Escalado




Importancia por Impureza de Gini



- Consolidación de 63 archivos CSV (2,51M)

- Selección de 29 variables continuas de red.
- Escalado Robusto con RobustScaler (IQR).

Sobremuestreo Adaptativo en la Frontera (Borderline-SMOTE1)



Generación Sintética Focalizada en S_{danger}

- Identifica muestras minoritarias en la frontera de decisión.
- Incrementa la presencia de *Web-based* de **683 a 50,000** muestras en entrenamiento.
- Evita la introducción de ruido sintético en regiones seguras.


Resultados de Eficacia Predictiva sobre Test Set Aislado ($N = 377,383$)

Modelo Evaluado	F1-Macro	Accuracy	Recall
Regresión Logística	0.4220	0.6120	0.4350
Árbol CART	0.6651	0.8124	0.6590
Random Forest Base	0.6791	0.8350	0.6750
LightGBM Base	0.6953	0.8420	0.6910
XGBoost GPU Base	0.6960	0.8435	0.6920
RF + Borderline-SMOTE	0.6850	0.8290	0.6820
XGBoost + Borderline	0.6995	0.8460	0.6950
Stacking Híbrido	0.7018	0.8485	0.6980

Recuperación de Clases Minoritarias

- *Brute Force*: F1-Score elevado a **41.40 %**.
- *Web-based*: F1-Score elevado a **33.86 %**.

Matriz de Confusión - Stacking Híbrido Propuesto (Meta-LightGBM)



Perfilado Computacional de Viabilidad en Pasarelas IoT de Borde

Métricas de Desempeño en Tiempo Real


- **Latencia por Muestra:** $8,65 \mu s$
- **Tasa de Procesamiento:** 115,613 paquetes por segundo.
- **Ocupación de RAM:** 257,89 MB (Cumple < 300 MB).

Ventaja frente a Deep Learning (CNN/LSTM)

- Redes profundas exigen latencias $> 100 \mu s$ y GPUs de alto consumo.
- El Stacking es **liviano, eficiente e interoperable** para pasarelas de borde (Raspberry Pi / Jetson Nano) vía ONNX.

Validación Estadística de Significancia (Prueba de Wilcoxon)

Distribución del F1-Macro en 30 Bloques de Prueba (Validación Estadística)



Prueba de Wilcoxon (30 Bloques)

- $W^+ = 95,0$
- $p\text{-valor} = 0,003744 < 0,05$

Conclusión Estadística

Se rechaza la Hipótesis Nula (H_0) y se acepta la **Hipótesis General (H_G)** con un nivel de confianza del **99.5 %**.

Conclusiones Principales y Aportes

- ① **Eficacia y Generalización:** La arquitectura Stacking con Entropía de Shannon alcanza un F1-Macro del **70.18 %** y Accuracy del **84.85 %**, superando estadísticamente a todos los modelos de control.
- ② **Neutralización del Sesgo:** Borderline-SMOTE1 y RobustScaler mitigan la paradoja de la exactitud, elevando la sensibilidad en intrusiones minoritarias (*Brute Force* a 41.40 % y *Web-based* a 33.86 %).
- ③ **Viabilidad en Borde:** La latencia de 8,65 μs y consumo de 257,89 **MB RAM** garantizan su despliegue operativo en pasarelas IoT de MYPEs y PYMEs.

¡Muchas Gracias por su Atención!

¿Preguntas o Comentarios del Jurado Evaluador?

Repositorio Oficial del Proyecto en GitHub:

<https://github.com/carmenNieves6478/>

DETECCI-N-DE-ATAQUES-MINORITARIOS-EN-REDES-IoT-MEDIANTE-UN-MODELO-H-BRIDO.git

Bach. Carmen Nieves

Universidad Nacional del Altiplano - Puno